

北京交通大学

硕士专业学位论文

基于时空图神经网络的地铁客流量预测模型研究

Research on subway passenger flow prediction model based on
spatio-temporal graph neural network

作者：潘路远

导师：黄华

北京交通大学

2024 年 9 月

学校代码：10004

密级：公开

北京交通大学

硕士专业学位论文

基于时空图神经网络的地铁客流量预测模型研究
Research on subway passenger flow prediction model based on
spatio-temporal graph neural network

作者姓名：潘路远

学 号：20140064

导师姓名：黄华

职 称：副教授

专业学位类别（领域）：软件工程

学位级别：硕士

北京交通大学

2024 年 9 月

摘要

随着城市化进程的加速,地铁网络作为城市交通的核心组成部分,其发展和人们出行需求的增长对轨道交通资源的优化配置带来了新的挑战。准确预测地铁客流量不仅对提高智能交通系统的运行效率至关重要,也是实现高效运输组织的关键。然而,现有地铁客流量预测方法存在诸多不足。一方面,现有地铁客流量预测方法在处理客流量时空数据时,往往忽视了数据的时空依赖性和动态变化特性,导致预测模型无法有效识别和适应不同区域及时间段的流量特征;另一方面,现有模型在新数据集适应性和周期性特征挖掘方面存在局限性。为了解决这些问题,本文提出了基于图神经网络的时空交通数据预测方法。

主要研究内容和取得的成果:

(1) 为了精确捕捉复杂交通网络中时间和空间因素对流量变化的共同影响,提出了一种时间感知动态图构造方法。通过图卷积和循环网络的结合,建模地铁网络的动态时空依赖性。模型的贡献在于通过图卷积层和循环层,加强了对交通网络每个时间步的时空依赖性捕捉。内置的参数化邻接矩阵通过自适应学习算法,动态调整每个时间步的图结构,从而提高对交通网络变化的响应速度和预测精度。与现有方法相比,本模型在处理复杂交通数据的动态性和时空交互性方面表现更优,实验结果表明,在准确性等关键指标上有较大提升。

(2) 为克服现有模型在新数据集适应性和周期性特征挖掘方面的局限性,本文提出了一种融合周期性特征识别和元学习机制的客流量预测模型。该模型通过时间嵌入技术,将时间信息编码为模型可以识别的格式,增强了对时间序列中周期性模式的识别能力。此外,应用对比学习技术和元学习策略,提升了模型的适应性和泛化能力。实验结果表明,该模型在开放数据集上的关键指标上有显著提升。

(3) 为了解决地铁客流量分析中的大规模时间序列数据集的快速聚合问题,本文设计并实现了一个地铁客流量分析平台。该平台通过 Redis TimeSeries 的高效聚合算法,冷数据和结果数据存储在 MySQL 中,并采用分层存储策略,优化了时间序列数据的存储和检索性能。此外,平台提供了一个基于 Web 的分析工具,支持实时数据展示、可视化分析等功能,大幅提升了用户体验。

本文提出的地铁客流量预测模型和分析平台,通过集成高效的算法和数据分析技术,提升了预测的准确性和模型对不同客流量模式的适应性。同时,通过直观的用户界面设计,增强了用户交互体验,使城市轨道交通系统能够更有效地规划运营策略和资源配置,进而提升运输效率和服务质量。

关键词: 地铁客流量预测; 图神经网络; 动态时空图; 周期特征; 元学习

ABSTRACT

With the acceleration of urbanization, the development of the subway network as a core component of urban transportation and the growth of people's travel needs have brought new challenges to the optimal allocation of rail transportation resources. Accurate prediction of subway passenger flow is crucial for enhancing the operational efficiency of intelligent transportation systems and achieving efficient transportation organization. However, existing subway passenger flow prediction methods often ignore the intricate spatiotemporal dependencies and dynamic changes in the data, leading to models that fail to effectively identify and adapt to traffic characteristics across different regions and time periods. Additionally, these models exhibit limitations in their adaptability to new data sets and in mining periodic features. To address these issues, this paper introduces a spatio-temporal traffic data prediction method leveraging graph neural networks. Our approach effectively captures complex spatiotemporal dependencies and dynamic changes by utilizing the topological structure of graph neural networks, which allows for the extraction of periodic patterns through graph convolution operations. This innovation not only enhances prediction accuracy but also improves the model's generalizability across various subway networks and time frames, offering a robust tool for intelligent transportation systems.

The main research content and results achieved:

(1) In order to accurately capture the joint influence of temporal and spatial factors on traffic changes in complex traffic networks, a time-aware dynamic graph construction method is proposed. The dynamic spatio-temporal dependence of metro networks is modeled through the combination of graph convolution and recurrent networks. The contribution of the model lies in the enhanced capturing of the spatio-temporal dependence of each time step of the transportation network through the graph convolution layer and the recurrent layer. The built-in parameterized adjacency matrix dynamically adjusts the graph structure at each time step through an adaptive learning algorithm, which improves the response speed and prediction accuracy to the changes in the transportation network. Compared with the existing methods, this model performs better in handling the dynamics and spatio-temporal interaction of complex traffic data, and the experimental results show that there is a large improvement in key indicators such as accuracy.

(2) In order to overcome the limitations of existing models in terms of new dataset adaptation and periodic feature mining, this paper proposes a passenger flow prediction model that incorporates periodic feature recognition and meta-learning mechanisms. The model enhances the ability to recognize periodic patterns in time series by encoding temporal information into a format recognizable by the model through temporal embedding techniques. In addition, contrast learning technique and meta-learning strategy are applied to enhance the adaptability and generalization ability of the model. The experimental results show that the model has significant improvement in key indicators on the open dataset.

(3) In order to solve the problem of fast aggregation of large-scale time series datasets in subway passenger flow analysis, this paper designs and implements a subway passenger flow analysis platform. The platform optimizes the storage and retrieval performance of time series data by using the efficient aggregation algorithm of Redis TimeSeries, storing the cold data and the result data in MySQL, and adopting the tiered storage strategy. In addition, the platform provides a Web-based analysis tool that supports real-time data display, visualization and analysis, which greatly improves the user experience.

The metro passenger flow prediction model and analysis platform proposed in this paper improves the accuracy of prediction and the adaptability of the model to different passenger flow patterns by integrating efficient algorithms and data analysis techniques. Meanwhile, the intuitive user interface design enhances the user interaction experience so that the urban rail transit system can plan the operation strategy and resource allocation more effectively, and then improve the transportation efficiency and service quality.

KEYWORDS: Metro passenger flow prediction; Graph neural networks; Dynamic spatio-temporal graph; Periodic features; Meta-learning

目 录

1 引言.....	1
1.1 研究背景和意义.....	1
1.2 国内外研究现状.....	2
1.2.1 基于统计学理论的预测方法.....	2
1.2.2 基于传统机器学习技术的预测方法.....	4
1.2.3 基于深度学习技术的预测方法.....	5
1.3 论文主要内容.....	9
1.4 论文内容组织.....	10
2 相关理论介绍	12
2.1 时空序列数据.....	12
2.2 循环神经网络.....	12
2.3 卷积神经网络.....	14
2.4 时间卷积网络.....	15
2.5 图卷积神经网络.....	16
2.6 元学习.....	18
2.7 本章小结.....	18
3 基于动态学习图的客流量预测模型	20
3.1 问题阐述与动态图学习模型构建	20
3.2 动态图学习模型的架构与关键组件	22
3.2.1 时间图生成模块.....	23
3.2.2 动态图卷积模块.....	24
3.2.3 时间特征提取模块.....	24
3.3 实验设置、数据分析与模型评估	25
3.3.1 实验环境与配置.....	25
3.3.2 数据集描述与预处理方法.....	25
3.3.3 评价指标与参数优化.....	27
3.3.4 实验结果展示与分析.....	28
3.4 本章小结.....	31
4 融合周期特征和元学习的客流量预测模型	33
4.1 客流量预测问题提出与建模	33
4.2 客流量预测融合模型框架	35
4.2.1 周期特征提取与嵌入.....	35
4.2.2 元学习增强模块.....	36
4.2.3 编码器-解码器框架	38

4.2.4 周期特征与元学习融合机制.....	39
4.3 实验设计、数据分析与模型评估	39
4.3.1 实验环境与配置.....	39
4.3.2 数据集.....	39
4.3.3 评价指标、参数设置.....	40
4.3.4 实验结果展示与分析.....	41
4.4 本章小结.....	44
5 地铁客流量分析平台的设计与实现	45
5.1 地铁客流量分析平台需求分析	45
5.2 地铁客流量分析平台系统设计	46
5.2.1 地铁客流量分析平台相关软件技术.....	47
5.2.2 地铁客流量分析平台系统架构设计.....	48
5.3 地铁客流量分析平台实现	50
5.4 本章小结.....	54
6 总结与展望.....	56
6.1 工作总结.....	56
6.2 工作展望.....	56
参考文献.....	58

1 引言

本章从地铁运营和管理的实际需求出发，阐述了地铁客流量预测研究的现实意义。首先，系统地介绍了国内外地铁客运量预测方法以及交通领域时间序列的基于统计学、机器学习、深度学习的预测方法的相关研究现状。其次，针对现有的客流量预测方法中存在的不足和问题，利用最新的时空图神经网络方法，对该问题进行深入研究，最后介绍了论文的组织结构。

1.1 研究背景和意义

近年来，城市轨道交通不断发展，方便了城市居民的出行，提升了城市交通运行效率，缓解了公共交通堵塞的压力，为人们带来更大的便利，节约了出行成本，优化了城市空间布局。对我国城市轨道交通运营线路及里程进行统计，结果显示，截至 2022 年 12 月 31 日，全国拥有轨道交通的城市有 55 个^[1]。自 1863 年伦敦地铁开通至今，世界城市轨道交通发展已有 160 年的历史。160 年来，世界城市轨道交通已经历了蒸汽机、内燃机和电气化时代，进入了高度自动化与信息化时代，新一轮科技革命和产业革命蓬勃发展，正推动着城市轨道交通向数字化、智能化的新时代迈进^[2]。因此，集成先进的信息技术、数据通讯传输技术、电子传感技术、电子控制技术及计算机处理技术，并运用于整个地面交通管理系统而建立的一种在大范围内全方位发挥作用的实时、准确及高效的智能交通系统（Intelligent Traffic System, ITS）应运而生。通过 ITS，可以达到缓解交通拥堵、改善交通环境和节约交通成本等作用。如图 1-1 所示，杭州 2024 年每日平均客流量超过 300 万人次。




图 1-1 杭州地铁近 7 年年平均日客流量

Figure 1-1 Average daily passenger flow of Hangzhou Metro in the past 7 years

"十四五"现代综合交通运输体系发展规划^[3]明确指出，超大特大城市轨道交通

加快成网，打造轨道上的都市圈，预期 2025 年城市轨道交通运营里程达到 10000 公里，枢纽机场轨道交通接入率达到 80%。建设都市圈多层次轨道交通网络，推进干线铁路、城际铁路、市域（郊）铁路、城市轨道交通融合衔接，合理推动轨道交通跨线运营。规划同时要求，坚持创新驱动发展，推动互联网、大数据、人工智能、区块链等新技术与交通行业深度融合，推进先进技术装备应用，构建泛在互联、柔性协同、具有全球竞争力的智能交通系统，通过推进自主化列车运行控制系统研发，推动不同制式的轨道交通信号系统和有条件线路间的互联互通。构建智慧乘务服务、网络化智能运输组织调度、智慧能源管理、智能运维等系统。推广应用智能安检、移动支付等技术构建智慧城市轨道交通^[3]。地铁作为智能交通系统中重要的组成部分，通过分析历史时空客流量数据来预测未来交通状况，让管理者实时感知交通道路网络的健康状况，及时采取解决方案来优化交通流量，从而提高道路交通效率，是建设智慧城市轨道交通重要的内容。

综上所述，本文将先进的深度学习应用于地铁客流量预测领域，分析现有神经网络预测方法的不足，结合时空交通数据自身特点，构建图网络和元学习预测方法，并开发一套流量管理平台，既满足现代化智能交通系统的建设需求，又符合国家发展战略。因此，本文开展的研究工作具有重要的现实意义和实际应用价值。

1.2 国内外研究现状

在过去的几十年中，大量研究者对交通数据预测任务开展了大量的研究和实验，提出了许多先进有效的算法和模型。作为交通流量预测的一种，在地铁客流量预测的研究过程中，参考交通流量预测的方法是必要的。因此，本文不仅调研了地铁客流预测的文献，还参考了其他交通领域的时空序列数据预测方法，为下一步研究提供方法支撑。

这些方法主要分为三大类：基于统计学的方法、基于传统机器学习的方法以及基于深度学习的方法。下面将详细介绍三类预测方法，并总结当前研究面临的难点及挑战。

1.2.1 基于统计学理论的预测方法

在交通流预测领域，传统统计方法主要集中于对路网特定观测点的时序数据进行建模、分析与预测。这些方法的核心在于利用统计学原理和交通特性构建回归模型。然而，这些方法依赖于人为建立的回归方程，其性能显著受限于回归分析的准确性。一些具有代表性的统计方法包括历史平均值(Historical Average, HA)^[4]、

自回归差分整合平均滑(Autoregressive Integrated Moving Average, ARIMA)模型^[5]、卡尔曼滤波(Kalman Filtering)模型、灰色预测模型(Gray Forecast Model, GM)等。

HA 法是一种较为简单的预测方法,该方法研究对象在同一位置相同时间间隔内的历史观测值取平均或加权取平均后作为预测结果,其计算复杂度低且易于部署。该算法简单,参数使用最小二乘在线估计,可以在一定程度内解决不同时间、不同时段里的交通流变化问题,但其没有考虑当前交通状态变化所带来的影响,不能反映动态交通流的不确定性与非线性特性,存在预测结果精度不高的问题。

ARIMA 预测模型是一种应用得最为广泛的时间序列模型。该模型不像其它时间序列方法一样需要固定的初始化模拟,通过若干次差分使非平稳数据转化为平稳序列,再用数学模型近似描述该随机序列,但种算法在预测具有稳定特性的时间序列的时候有比较良好的性能;缺点是这种算法构建的模型因其属于线性模型,所以只能进行线性预测。其特别适用于稳定的交通流,当交通状况变化急剧时,由于计算量过大,该模型将在预测延迟方面暴露出明显的不足。此外,该模型基本上是从纯时间序列分析的角度进行预测,并没考虑上下游路段之间的相关性。赵等人^[6]通过优化 ARIMA 模型参数对不同时间粒度下天津地铁某站点周一到周五的 AFC 客流数据进行预测,预测结果表明 ARIMA 方法能够准确预测城市轨道交通站点的短期客流,小客流数据时间粒度能够获得更多的客流数据细节信息,有利于提升预测的精准度。张等人^[7]加入遗传算法来优化模型,使训练集能够更好地趋于平稳化,随着迭代次数的逐步增长,数值会更快地趋于稳定状态并且达到最优值,结果表明预测模型预测精度更高,可以提供更加准确的预测结果。

卡尔曼滤波,是一种先进的控制方法,是一种基于线性回归的预测方法。其采用由状态方程和观测方程组成的线性随机系统的状态空间模型来描述滤波器,并利用状态方程的递推性,按线性无偏最小均方误差估计准则,采用一套递推算算法对滤波器的状态变量作最佳估计,从而求得滤掉噪声的有用信号的最佳估计^[10]。卡尔曼滤波法具有预测因子选择灵活、精度较高的优点,是最好的预测方法之一。但是,由于模型的基础是线性估计模型,所以当预测间隔较小时,交通流量变化的随机性增强,模型的性能是否会变差,还值得进一步研究^[11]。此外,由于在每次计算时都要调整权值,需要作大量的矩阵和向量运算,导致算法较为复杂。

灰色预测模型具有一个区别于其他预测模型的重要特点,在于该模型采用的是根据原始数列生成的数列,而非直接对原始数列进行建模。灰色模型在灰色预测理论中占有最重要的地位,所谓的灰色模型就是指通过将原始数据利用有关的方法进行重新生成并得出近似于指数规律的数据列,然后再对其进行建模。成向立^[8]以上海地铁 15 号线为研究对象建立指标体系,引入灰色关联模型分析各指标对客流规模偏差的影响程度。结果表明非直线系数、站点重要度和竞争公交对客流偏差

率影响程度较大,配套公交条数和私人交通竞争力也有一定影响。褚文斌等人^[9]运用灰色理论方法,以西安地铁二号线具体实际调查所得站点客流为例,运用两种灰色模型对客流量进行预测,并对结果采取精确度的验证以探求其可行程度及适用程度,来达到优化轨道交通的运行质量和效率的目的。

以上基于统计分析的预测方法虽然较为简单且容易实现,但大多基于线性模型,需要先验知识手动设定模型的参数,难以建模实际交通场景中复杂的复杂非线性关系,越来越不能满足实际精度和现代智能交通系统的需要。

1.2.2 基于传统机器学习技术的预测方法

随着技术的进步,机器学习技术已被广泛应用于交通流预测领域。该技术适用于系统所固有的非线性特性,尤其适用于那些具有良好误差分布的预测任务。与传统方法相比,机器学习无需依赖先验知识,仅需依赖于充分的历史数据,即可对交通数据进行有效建模,并从中挖掘出更为复杂的相关性。在机器学习领域,K最近邻(K-Nearest Neighbor, KNN)算法、支持向量回归(Support Vector Regression, SVR)以及梯度提升决策树(Gradient Boosting Decision Tree, GBDT)等方法已成为解决交通流预测问题的经典算法。这些方法通过利用历史数据的内在模式,为交通流量的预测提供了一种更为精确和高效的途径。

Davis 等人^[12]首次建立了 KNN 算法的交通流预测模型。他们与单变量线性时间序列方法进行了比较,并提出增加数据量的方法可以提高当前模型的预测精度。然而,由于 KNN 算法需要从历史数据中寻找近邻值来进行下一时刻的预测,并且会保留原始输入数据,这导致算法的时间成本增加,损失了一定的运算速度。KNN 算法参数 K 值的选择对模型的预测准确性有很大影响。为了减少参选择的影响,彭等人^[13]结合 K 近邻非参数回归和地理加权回归模型,采用样本之间的属性差异表征异质性特征,提出一种属性加权回归模型,对城市进出站客流在不同尺度下表现出截然不同的空间分布特征的进行建模。郇等人^[15]结合地铁客流数据数据特性改进近邻样本的模式匹配过程,根据样本间流量差异引入距离权重和趋势系数,推演未来时段的进站量,取得了良好效果。

SVR 是一种基于支持向量机(Support Vector Machine, SVM)的回归方法。它利用核函数将输入数据映射到高维空间中,使得非线性关系在新的特征空间内变为线性可分,从而进行有效的回归分析。常用的核函数包括线性核、多项式核、径向基核(RBF)和 Sigmoid 核等。核函数的选择对 SVR 的性能有重要影响,通常需要根据具体问题来选择合适的核函数和参数。Wu 等人^[16]应用 SVR 进行旅行时间预测,并将其结果与其他使用真实高速公路交通数据的基线旅行时间预测方法

进行比较。由于支持向量机具有更强的泛化能力,结果表明 SVR 预测可以显著降低预测旅行时间的相对平均误差和均方根误差。

梯度提升算法是一种强大的机器学习技术,它通过迭代地添加模型来改进性能,特别适用于复杂的非线性问题。该算法的灵活性和预测精度高,尤其在处理结构化数据时表现出色。然而,这种算法也有其缺点,如训练时间长,对参数选择敏感,且可能在某些情况下过拟合。韩等人对线网结构特征、时间维度特征进行构建,建立基于 LightGBM 算法的轨道交通短时客流预测模型,并对模型参数进行标定,采用模型评估和特征重要性分析等方法,表现出较强的预测性能^[17]。

总之,在交通流预测的机器学习方法中,机器学习模型的结构相对简单,能够高效地处理简单数据集,并能对交通流的非线性关系进行一定程度的挖掘。然而,基于机器学习的模型性能在很大程度上取决于特征工程和专家经验。因此,为了更深入地理解交通流的复杂时空特性,仍需提升模型对这些特性的挖掘能力,特别是在分析大规模数据集和复杂的路网结构时,特征提取的难度显著增加,这要求模型必须具备更高级的数据处理和建模能力。

1.2.3 基于深度学习技术的预测方法

深度学习的发展历程是人工智能领域中一段引人入胜的历史。其根源可追溯至 20 世纪 40 年代初的神经网络概念。尽管早期由于计算资源的局限性,深度学习的发展步履维艰,但它在 21 世纪初期随着计算技术的飞速进步和大数据时代的到来而迅猛发展。在语音识别、自然语言处理等多个序列数据领域,深度学习技术已经取得了突破性的进展,并开始在交通流量预测等实际应用中展现其价值。

交通流数据,作为多维时间序列数据的一个典型实例,其内在的复杂性和动态性要求应用高效的分析技术。这些数据表现出显著的时间连续性和空间相关性,对于理解和预测交通模式具有关键意义。因此,开发能够精确捕捉这些维度特征的先进分析方法显得尤为重要。在交通流预测的研究领域,循环神经网络(Recurrent Neural Network, RNN)^[18]、卷积神经网络(Convolutional Neural Network, CNN)^[22]以及注意力机制等模型已被证明能够有效捕捉时间序列的依赖结构。此外, CNN、GNN 以及注意力机制的综合应用,为模拟空间依赖性提供了有力的策略,这些技术融合成为处理时空数据的复合型工具。

递归神经网络及其衍生的变体,包括长短期记忆网络(Long Short-Term Memory networks, LSTM)、门控循环单元(Gated Recurrent Units, GRU)^[18]以及 Transformer 模型,在处理时间序列数据方面展现了显著的效果。这些模型的结构设计使得它们能够通过循环的内部状态传递,有效地处理并存储输入数据流中的

信息。在捕捉交通流数据的时间序列特性方面,这些模型相较于传统机器学习技术显示出了明显的优势。Du 等人^[23]将分层集聚类、标准化欧几里得距离和长短期记忆网络(LSTM)相结合,提出了一种交通流预测模型。该模型对原始交通流数据样本集进行聚类分析,将流量数据分类并计算目标路段所在路网的空间相关性,利用与目标检测路段最相关的 K 个路段构建 LSTM 输入数据矩阵最终预测结果。然而,LSTM 的结构相对复杂,计算成本较高。相比之下,GRU 通过两个门来控制信息流,结构更简洁,计算效率更高,成为一个有效的替代方案。Wu 等人^[24]的研究利用荷兰交通管理部门的数据,每五分钟预测一次车流量,通过对比 LSTM 和 GRU 的预测精度,验证了 GRU 流量预测模型的高效性能。

然而,传统的循环神经网络(RNN)及其变体在处理交通流数据时,常常将数据视为独立信号流,未能充分考虑数据的空间依赖性,这限制了它们在捕捉空间相关性方面的效能。早期的空间特征提取主要依赖于卷积神经网络,但这种方法未能有效整合时间序列数据的空间相关性。为了解决这一问题,Ye 等^[25]研究者提出了一个新颖的模型,该模型融合了卷积神经网络和长短期记忆网络,以预测短期交通流。该模型利用 CNN 来探索交通流的空间特性,并通过 LSTM 捕捉时间动态,进而整合时空特征以提高预测准确性。实验结果验证了 CNN-LSTM 模型在减少预测误差方面相较于其他模型具有显著优势^[26]。然而,CNN 主要适用于欧几里得空间的数据处理,这是因为它们的结构特别适合处理具有规则网格结构的数据。因此,对于非欧几里得空间,例如路网这类复杂的图结构,CNN 的应用就受到限制。

交通网络可以精确地描述为一个复杂的图论模型,其节点代表各个站点,而边则表示站点间的连接路径及客流方向。图卷积操作利用图表示对非欧氏空间数据进行处理,使卷积操作更加适用于交通数据结构。受到图神经网络在拓扑图建模方面的应用启发,研究者们提出了时空图神经网络。这是一种结合了时序模型和图卷积网络的先进深度学习框架,旨在构建用于复杂、非线性交通流量预测任务的模型。

图神经网络将空间特征提取于图卷积操作之中,但当提取空间特征与时序特征相结合的方法被用于交通预测问题时,人工智能在该领域的潜力才得以真正释放。大量的研究工作将图神经网络融入到序列模型(如卷积神经网络 CNN 和递归神经网络 RNN),以学习交通数据的时间和空间依赖性。这种集成方法已经证明能够达到先进水平,并展现出卓越的性能。

(1) 时序特征的提取方法

在时间序列特征提取的研究中,卷积神经网络(CNN)和循环神经网络(RNN)是两种主要方法。时间卷积网络(Temporal Convolutional Network, TCN)^[19]是一种为时间序列数据特别设计的架构,它利用一维卷积层和扩张卷积(dilated convolutions)有效捕捉时间序列中的长距离依赖性。这种方法不仅克服了 RNN 在

处理长序列时可能出现的梯度消失问题,而且得益于其并行计算能力,显著提高了模型的运算效率。一系列模型如 GWN^[31], MTGNN^[38], STFGNN^[46], DMSTGCN^[49]等,都采用了 Dilated TCN 作为其核心组件,以增强对时间序列特征的提取能力。这些模型通过利用扩张卷积来扩大感受野,同时保持了时间序列数据的因果性和前瞻性。STGCN^[28]和 LSGCN^[35], STAG-GCN^[40]进一步引入了带门控机制的 TCN (Gated TCN),以增强模型对时空特征的提取能力。这些模型通过结合空间结构的图卷积和时间维度上的门控时间卷积,有效地同步捕获了交通数据的时空动态性。然而,TCN 在处理时间序列长度增加时,其内存占用量亦随之增长,特别是在深层网络结构中。此外,TCN 的性能受到网络结构参数(如卷积层数量、扩张系数等)的影响,需细致调整以优化性能。

循环神经网络(RNN)及其变体,如门控循环单元(GRU),已被广泛应用于捕获时间依赖性。GRU 通过引入更新门和重置门两个关键组件,有效解决了传统 RNN 在处理长序列时遇到的梯度消失问题。这种设计简化了模型结构,减少了参数数量,从而提高了训练效率,并且通常在资源有限的情况下也能表现出与 LSTM 相当或更优的性能。一系列的模型,如 DCRNN^[29], Meta-GRU^[34], AGCRN^[39], T-MGCN^[41], GTS^[44], DGCRN^[45], CCRNN^[47], RGSL^[50]都使用 GRU 来对时间依赖进行建模,这些模型利用 GRU 的门控机制,有效地处理了时间序列数据中的时间依赖问题。

与此同时,Transformer 模型通过自注意力机制能够并行处理序列中的所有元素,这与 RNN 的序列处理方式有显著区别,使得 Transformer 能够捕捉到更广泛的长距离依赖关系。模型如 STGNN^[43], STEP^[52]等均采用了 Transformer 架构进行时间依赖性建模。但是,Transformer 的自注意力机制在计算和内存方面的要求较高,尤其是当处理长序列或大规模数据集时。

(2) 空间特征的提取方法

图神经网络利用图结构来模拟交通系统中的非线性依赖性和动态变化,从而在交通预测领域展现出其强大的潜力。图神经网络不仅能够提高预测的准确性,还能帮助城市规划者和政策制定者更好地理解和管理城市交通流量,为智能交通系统的发展提供支持。

在交通流预测的研究范畴内,图神经网络(Graph Neural Networks, GNN)^[21]主要分为两个框架:图卷积网络(Graph Convolutional Network, GCN)和图注意力网络(Graph Attention Networks, GAT)。GCN 框架通过在图结构上实施卷积变换来优化节点表示,而 GAT 框架则采用注意力机制来识别和量化节点间的交互作用。这些方法的核心目标是精确地模拟交通网络内的时间和空间依赖性。

对于 GCN,图结构的定义是至关重要的。图的构造策略通常划分为静态图、自

适应图和动态图三种主要类型。如 DCRNN^[29]、MRA-BGCN^[42]等模型基于路网节点间的静态距离构建了静态图。STSGCN^[36] 则依据节点间的连通性生成图结构。此外, 还有研究^[38]通过嵌入矩阵构建自适应图, 以适应变化的交通条件。还有一些模型如 DGCRN^[45]、ESG^[51]、PGCN^[66]不同时间尺度上构建动态图^[56], 捕捉节点间的时变关系。PVGCN^[55]和 ST-MGCN^[33]构建了融合多种图信息的时空图, 并结合 GRU 模块, 通过并行融合多图信息实现最终预测。RGSL 模型^[50], 将显式先验结构和隐式结构结合起来的方法。于是他们提出了正则化图结构学习 (RGSL) 模型, 将显式先验结构和隐式结构结合起来用图结构学习预测深度网络。这些方法体现了图结构在适应不同交通场景中的灵活性和动态性。

然而, GCN 在捕捉图中距离较远节点间的依赖关系方面存在局限, 主要关注局部邻域信息。相对地, GAT 框架^[61]通过注意力机制有效地捕捉和建模空间特征, 为理解交通流中的复杂空间关系提供了灵活性。一些模型如 GaAN^[30]、ASTGCN^[32]、STGNN^[43]均采用了注意力机制, 这些模型通过自适应地分配不同节点间的关注度, 能够更准确地捕捉交通网络中的关键交互, 从而提高了预测精度。这种机制的引入, 使得 GAT 框架在处理交通流的空间特征方面具有显著优势, 尤其是在模拟交通流中的复杂空间相关性时。尽管 GAT 在处理交通流的空间特征方面具有优势, 但也存在训练数据过拟合的风险, 特别是在节点特征较少的情况下。

(3) 外部因素融合

当谈到交通状况时, 外部因素对其影响显而易见。这些因素例如道路结构和连通性, 可以从原始时间序列或邻接矩阵中生成。此外, 其他一些特征^[41]包括天气、交通事件、兴趣点 (POI), 需要额外的收集和预处理。

为了更好地协调不同的外部因素, 甚至生成新的有用特征, 需要深入研究这些因素之间的相互作用。例如, 将天气数据与交通流量预测相结合, 可以提高准确性。此外, 考虑到时间、道路结构和其他因素, 可以构建更全面的交通预测模型。总之, 综合利用这些外部因素并生成相关特征, 有助于更准确地预测交通状况。研究人员不断探索创新方法, 以利用这些见解来改进交通预测模型。

尽管已经设计了许多时空图网络变体来加强时空依赖的学习, 近年来, 越来越多的高级学习框架被开发出来, 以进一步提高时空图网络在深度表示和预测准确性方面的性能^[62]。这些框架包括元学习、自监督学习, 各自具有独特的优势, 但也存在一定的不足。

元学习, 也被称为“学会学习”, 旨在通过训练模型以快速适应新任务。在 STGNN 中, 元学习可以使模型通过在多个时空任务上进行训练, 从而迅速调整到新的时空数据分布。例如, Pan 等^[63]提出了一种基于深度元学习的城市交通预测方法, 通过在不同城市的交通数据上训练模型, 提升了模型对新城市环境的适应能力。

元学习方法面临计算复杂性高、任务间适应性问题和样本效率低等挑战。特别是在任务分布差异较大的情况下，模型的适应能力可能受到限制。

自监督学习通过从数据本身生成标签来训练模型，减少了对标注数据的依赖。在 STGNN 中，自监督学习可以利用未来时刻的数据作为当前时刻的标签，或通过预测数据的缺失部分来进行训练，从而提升模型对时空数据的理解能力。例如，Li 等^[64]提出了自节奏图对比学习方法，从而提高了模型对复杂时空关系的挖掘能力。自监督学习面临标签噪声、训练策略设计困难和模型复杂性高等问题。

这些高级学习框架的引入，不仅提升了 STGNN 在深度特征表示和预测准确性方面的能力，而且也推动了相关领域的研究进展。通过针对这些框架的不足进行优化，STGNN 在处理复杂时空数据问题上的潜力和价值将得到进一步增强。

1.3 论文主要内容

在当前交通网络研究的深入探讨中，站点动态时空关联性的深度挖掘面临着严峻的挑战。本文针对这一核心难题，设计并提出了新的研究框架，旨在弥补现有研究在挖掘此类动态时空依赖性信息方面的不足，从而提升地铁交通客流量分析的精确度和前瞻性。主要研究内容如下：

首先，针对复杂交通网络中动态空间关系的复杂性，本文构建了一种基于动态图卷积循环网络的交通流量预测模型。该模型通过结合图卷积和循环神经网络的优势，更有效地捕捉交通网络的动态时空特性。通过每个时间步图卷积层和循环层，加强了对交通网络的时空依赖性捕捉，这允许模型在不同时间步上理解和预测交通流量的变化。内置的参数化邻接矩阵通过自适应学习算法，使模型能够根据实时数据动态调整其结构，从而提高对交通网络变化的响应速度和预测精度。

其次，针对现有模型在处理新数据集和周期性特征挖掘方面的局限，本文创新性地提出了一种融合周期性特征与元学习学习的客流量预测模型。该模型引入时间嵌入机制，能够将时间信息编码为模型可以识别的格式，显著提升了对周期性模式的识别能力，这对于理解交通流量的日常和季节性变化至关重要。同时通过元学习学习技术，增强了模型对空间依赖性的捕捉，从而显著提高了预测的准确性。通过引入先进的时间序列分析和机器学习技术，不仅提升了预测性能，还为深入理解交通系统中时间依赖性关系提供了新的理论洞察视角，有助于优化交通管理策略和提高运营效率。

最后，为了满足实际应用的需求，本文详细阐述了地铁客流量分析平台的设计与实现。平台在满足系统需求的同时，引入了的时间序列数据处理技术，以增强其在时序数据分析中的性能。用户界面设计注重用户体验，通过清晰的布局、直观的

导航，注重直观性和易用性，确保用户能够轻松地进行数据分析和决策支持，为用户提供了一个高效且友好的工具，以深入分析地铁客流量的动态变化，优化运营决策，提升乘客出行体验。

综上所述，本文通过创新的模型设计和平台构建，提高了地铁流量预测的准确度，并设计了一个直观的平台，集成了预测模型和数据分析工具，从而提升了城市交通系统的智能化和效率，为交通管理提供了强有力的决策支持。

1.4 论文内容组织

本文主要针对地铁客流量的准确预测问题，考虑到现有方法在处理时空变化和周期性特征方面的局限性，提出了一种动态图卷积模型作为解决方案，该模型能够更有效地捕捉客流量的时空动态性。在这个过程中，认识到地铁客流量的复杂性，特别是在时空变化和周期性特征方面的处理困难。因此，本文对现有的模型进行了深度的研究，并采取了相应的改进措施以提高预测精度。本篇论文将从动态时空关系和周期特征的角度出发，深入分析地铁客流量，因为这些因素对于理解客流量的波动模式和提高预测精度至关重要。全文由六大部分组成，每部分都有独立的主题和结构。以下是主要章节的排列顺序及主要内容概述。

第一章：引言。本章首先从研究背景和意义入手，全面而系统地阐述了国内外地铁客流量预测以及交通领域时空序列预测的各种模型方法。同时，也详细指出了当前客流量预测方法在处理大规模数据、实时性要求以及复杂时空依赖关系方面所面临的挑战和问题，进而明确了本文的研究重点。最后，对论文的组织结构进行了简要介绍。

第二章：相关理论介绍。本章主要介绍了深度学习相关的理论知识，以及与交通量相关的理论知识。其中，深度学习的概念，以及图神经网络在处理非欧几里得结构数据、循环神经网络在捕捉时间序列依赖性、卷积神经网络在提取空间特征方面的应用，都是本研究重点关注的对象，因为它们对于构建有效的客流量预测模型至关重要。

第三章：基于动态学习图的客流量预测模型。本章首先详细介绍了提出的动态图卷积地铁流量预测模型。在此基础上，对现有构图方法进行了深入分析，发现大多数方法采用静态图卷积网络，且其邻接矩阵如路网结构和距离图等往往需要基于先验知识手动构建。为了解决这一问题，提出了一种全新的数据驱动的图构建方法。这种方法使用参数化的邻接矩阵，根据数据动态构建节点间的时间图。随后，详细描述了模型的总体架构，并对每个组件的设计进行了详尽说明。最后，通过一系列的对比实验和消融实验，验证了模型的有效性。

第四章：融合周期特征和元学习学习的客流量预测模型。本章首先分析了模型在泛化能力和适应新数据方面的不足之处，以及在时间特征利用和周期性依赖捕捉方面的缺陷。然后，引入了时间嵌入和元学习学习的概念，并阐述了它们在模型中的重要性。接着，再次详细介绍了模型的总体架构，并对每个组件的设计进行了详尽说明。最后，通过一系列的对比实验和消融实验，验证了模型的有效性。

第五章：地铁客流量分析平台的设计与实现。在这个部分里，首先介绍了平台的系统需求、系统设计以及技术框架。然后，介绍了时间序列数据处理方法，并详细展示了平台各功能的设计与实现效果。

第六章：总结与展望。本章对全文的研究成果和实验结果进行了全面回顾，并对当前工作的不足之处进行了深入剖析。最后，对未来的研究方向和可能的改进空间进行了展望，为下一步的研究工作打下了坚实基础。

本文的组织结构如图 1-2 所示：




图 1-2 论文组织结构

Figure 1-2 Organization of the paper

2 相关理论介绍

2.1 时空序列数据

时空序列数据作为一种整合时间和空间维度信息的数据集，具有捕捉不同地理位置随时间演变动态变化的能力。其独特之处在于，每个数据点不仅与时间戳密切相关，还与其所在的空间坐标紧密相连，展现了强烈的时空关联性。在学术领域中，这类数据被广泛运用于气象学、地理信息系统、环境科学、交通流量分析以及社会经济预测等多个研究领域。通过深入分析时空序列数据，研究者能够洞察复杂系统的内在模式与趋势。

以交通客流量数据为例，这类数据集是时空序列数据的典型代表，它不仅揭示了时间与空间维度上的动态变化，而且由于其庞大的数据量，需要采用高效的分析与工具。这些技术与工具必须能够应对数据的时空异质性——即不同时间点和不同地理位置的交通状况可能存在显著差异，以及非平稳性——即交通数据的统计特性随时间的演变而变化，不满足传统时间序列分析中对数据平稳性的严格要求。

随着数据分析技术的不断发展，处理时空序列数据的方法也在不断创新，包括但不限于时间序列分析、空间统计分析、机器学习和深度学习等。这些方法的应用不仅提高了预测准确性，还优化了资源配置，并在决策支持系统中发挥了关键作用。

2.2 循环神经网络

循环神经网络（Recurrent Neural Network, RNN）是一种强大的神经网络模型，专为处理序列数据而设计。其核心特点在于网络中的神经元不仅与前一层的神经元相连，还与自身的先前状态相连，形成了一个内部循环。这种结构使得 RNN 能够保持对先前信息的记忆，并利用这些信息影响当前及未来的决策。因此，RNN 特别适合于那些输入数据与时间顺序紧密相关的任务，如语音识别、自然语言处理和时间序列分析。

RNN 的另一个显著特点是其灵活性，能够处理各种长度的输入序列。不同于传统的前馈神经网络（Feedforward Neural Networks），RNN 能够通过其循环连接捕捉长距离的数据依赖关系。这一特性使得 RNN 在诸如机器翻译、文本生成等复杂任务中表现出色，其模型结构如 2-1 所示。然而，RNN 也存在梯度消失或爆炸的问题，这限制了其在实际应用中处理长序列的能力。为了克服这些问题，研究者们

开发了 RNN 的变体，如长短期记忆网络（Long Short-Term Memory, LSTM）和门控循环单元（Gated Recurrent Unit, GRU），它们通过特殊的门控机制来调节信息的流动，从而更有效地学习长期依赖关系。长短期记忆网络（LSTM）和门控循环单元（GRU）是 RNN 的两种重要变体，它们都能够捕捉长距离的数据依赖关系，但在结构和运算上有所不同。LSTM 设计了三个门：输入门、遗忘门和输出门，这些门控制着信息的存储、更新和输出，使得 LSTM 能够在长序列中有效地保持和传递信息。

GRU 通过使用更新门和重置门来解决传统循环神经网络（RNN）中的梯度消失问题。更新门帮助模型决定在每个时间步保留多少之前的信息，而重置门则决定忽略多少之前的信息。这种结构使得 GRU 能够在不同时间尺度上捕捉信息，并且在长序列中保持稳定的性能。相比 LSTM，GRU 结构更为简洁，参数更少，计算效率更高，训练时间更短。其中 u 为控制更新的门控（update gate），见公式(2-1)， r 控制重置的门控（reset gate），见公式(2-2)。重置门允许控制可能还想记住的过去状态的数量；更新门将允许控制新状态中有多少个是旧状态的副本。

$$u_t = \sigma(W_u \cdot x_t + U_u \cdot h_{t-1} + b_u) \quad (2-1)$$

$$r_t = \sigma(W_r \cdot x_t + U_r \cdot h_{t-1} + b_r) \quad (2-2)$$

$$\tilde{h}_t = \tanh(W_c \cdot x_t + U_c (r_t \odot h_{t-1}) + b_c) \quad (2-3)$$

$$h_t = u_t \odot h_{t-1} + (1 - u_t) \odot \tilde{h}_t \quad (2-4)$$




图 2-1 RNN Cell 模型^[18]

Figure2-1 RNN Cell Model

序列到序列（Sequence to Sequence, seq2seq）模型^[20]是一种深度学习框架，旨在处理那些输入和输出均为序列的问题，例如机器翻译、自动摘要和问答系统。该模型的核心是一个编码器-解码器架构，其中编码器部分将输入序列转换成一个固定长度的向量，而解码器部分则将该向量转换回一个目标序列。seq2seq 模型的一个关键创新是其能够处理可变长度的输入和输出序列，这在传统的神经网络架

构中是难以实现的。此外，seq2seq 模型通常与注意力机制（Attention Mechanism）结合使用，以提高对长序列的处理能力，通过在解码过程中动态地聚焦于输入序列的不同部分，从而改善模型的性能和灵活性。seq2seq 模型的成功应用已经推动了自然语言处理领域的许多进步，seq2seq 模型结构如下图所示。




图 2-2 seq2seq 模型^[20]

Figure2-2 The seq2seq model

综上所述，循环神经网络通过其独特的循环结构，在序列数据处理方面展现出了巨大的潜力和灵活性。尽管存在一些挑战，但 RNN 及其变体仍然是深度学习领域中不可或缺的工具，广泛应用于各种复杂的序列建模任务中。

2.3 卷积神经网络

卷积神经网络（Convolutional Neural Network, CNN）^[22]，作为深度学习领域的重要算法，因其在图像识别、语音处理等多个领域的卓越表现而备受瞩目。CNN 的设计巧妙地结合了卷积层、池化层和全连接层，以实现复杂数据的高效处理。

卷积层是 CNN 的灵魂，它通过一组可学习的滤波器（或称卷积核）对输入数据进行操作。这些滤波器在空间维度上与数据进行卷积，从而逐点提取出输入数据的局部特征。这一过程的关键在于滤波器参数的优化，通常通过反向传播算法和梯度下降法调整，以适应数据的特性。

池化层则在卷积层之后发挥作用，其主要任务是降低数据维度，减少计算负担，同时防止过拟合。常见的池化方法有最大池化和平均池化，前者选择区域内最大值作为代表，后者取平均值。这两种方法都能有效地保留重要特征，同时降低数据的复杂性。

全连接层作为 CNN 的最终输出层，将前一层的所有节点连接到当前层，用于将学习到的特征映射到具体的输出。在实际应用中，全连接层通常位于网络的末尾，

用于分类或回归任务。

CNN 的工作流程是：首先通过卷积层提取特征，然后通过池化层进行降维处理，最后通过全连接层将特征转化为预测结果。这种结构使得 CNN 在处理欧式空间（如图像和语音）中，由于数据的局部相关性，能够展现出极高的性能。然而，对于非欧氏空间，如自然语言处理中的文本数据，由于输入维度的不固定和结构的复杂性，CNN 可能不那么适用。

在实际应用 CNN 时，需要充分考虑其优点（如特征提取能力强、计算效率高）和缺点（如对输入数据结构敏感），根据具体任务和环境，灵活选择合适的网络架构、优化策略和预处理方法。例如，对于文本数据，可能需要引入循环神经网络（RNN）或 Transformer 结构，以适应序列数据的特点。总的来说，理解并灵活运用 CNN，是提高深度学习模型性能的关键。

2.4 时间卷积网络

时间卷积网络（Temporal Convolutional Network，简称 TCN）是一种专为序列建模和预测而设计的神经网络架构。TCN 借鉴了 CNN 的卷积操作，通过扩张的、因果的一维卷积层来处理具有相同输入和输出长度的数据，从而保证了模型在处理时间序列数据时的因果性和顺序性。这种架构的优势在于其具有在时间维度上捕捉模式和长程依赖关系的能力，同时通过使用卷积层而非循环层来处理序列依赖关系，避免了传统递归神经网络（RNN）中常见的梯度消失或爆炸问题。TCN 的另一个显著特点是其并行化能力，这使得模型训练更加高效。在多个领域的实际应用中，TCN 已经证明了其在序列建模任务中的有效性，尤其是在需要处理长序列数据的场景下。此外，TCN 的结构允许灵活地调整卷积层的大小和数量，以适应不同复杂度的任务需求。

(1) 门控时间卷积网络

受 LSTM 和 GRU 中的门控机制的启发，通过引入门控单元来动态调节信息流，从而有效地捕捉时间序列中的长期依赖关系。这种网络通常包含多个卷积层，每个层都通过门控单元来控制信息的传递，使得网络能够在保持时间信息连续性的同时，过滤掉不相关的信息，提高了模型对时间序列预测的准确性和鲁棒性，其计算原理为两个卷积进行对应点成运算，见公式(2-5)。

$$F(x) = \tanh(\Theta_1 \star x) \odot \sigma(\Theta_2 \star x) \quad (2-5)$$

(2) 因果时间卷积网络

因果时间卷积网络（Causal Time Convolutional Networks, TCNs）是一种先进的神经网络架构，其设计原则在于确保网络的预测输出严格依赖于时间序列中的先

前和当前状态，排除了未来信息的潜在干扰，这一属性被称为因果性。该网络通过引入因果卷积层来实现这一特性，其中每个卷积操作均限定于与当前和之前时间步的交互，有效避免了信息泄露的问题。

进一步地，TCN 采用了膨胀卷积（Dilated Convolution）技术，以扩展网络的感受野，使其能够捕捉到时间序列中更广泛的依赖模式，同时保持计算效率。通过逐步增加的膨胀因子，TCN 能够学习从局部到全局的时间依赖关系。




图 2-3 TCN 模型图
Figure 2-3 TCN model diagram

膨胀卷积的计算方式如公式所示：

$$F(s) = (x_d^* f)(s) = \sum_{i=0}^{k-1} f(i) \cdot x_{s-d \cdot i} \tag{2-6}$$

总体而言，TCN 为序列数据的分析和预测提供了一种强大且适应性强的解决方案。然而，TCN 在设计上存在一定的局限性。其一维卷积核的大小和网络层数可能限制了模型对时间序列中更复杂信息的捕捉能力，这在处理高度复杂的时空关系时可能导致性能受限。此外，随着网络层数的增加，模型的参数量也随之增长，这可能增加了模型过拟合的风险，尤其是在数据量有限的情况下。

2.5 图卷积神经网络

图卷积神经网络（Graph Convolutional Networks, GCN）^[21] 是一种深度学习模型，专为处理图结构数据而设计。它们的核心特点是能够直接在图上执行卷积操作，从而有效地提取节点特征并进行表示学习。与传统的卷积神经网络（CNN）相比，GCN 不需要将图结构数据转换为欧几里得空间，因此能够保留图数据的拓扑结构。GCN 通过利用节点的邻域信息，能够捕捉节点间复杂的关系和交互作用，如图 2-4 所示。这种方法在节点分类、链路预测等图基础任务中表现出色。此外，GCN 的训练过程中还可以学习到图的嵌入表示，这对于图相似性分析和图生成任务尤

其有用。总的来说，图卷积神经网络通过其独特的结构和算法，为图数据分析和处理提供了一种强大的工具。




图 2-4 GCN 特征聚合

Figure 2-4 GCN feature aggregation

为了实现这一点，GCN 采用了谱方法或空间方法。谱方法基于图的拉普拉斯矩阵的特征分解，而空间方法则直接在图的节点上聚合邻居的特征信息。

谱方法基于图论中的拉普拉斯矩阵，通过图的傅立叶变换将图信号转换到谱域，然后在这个域内应用滤波器。这种方法能够捕捉图的全局特性，但每当底层图结构发生变化时，都必须重新计算图拉普拉斯矩阵，它在处理大型图时会遇到计算效率和可扩展性的问题。此外，谱方法的滤波器是全局定义的，这意味着它们对图的结构非常敏感，对于结构有微小变化的图，滤波器可能需要重新设计。相比之下，空间方法直接在图的节点上进行操作，通过聚合每个节点的邻居信息来更新节点的特征表示。这种方法更加直观，因为它模仿了传统卷积神经网络中的局部感受野机制。

空间方法，能够适应图结构的变化，并且易于处理大型图。为了克服对图拉普拉斯矩阵的依赖性，通过在空间域中执行消息传递来简化图卷积运算。将这种新形式称为空间 GCN，其定义见公式(2-7)，其中 $\mathbf{A}$ 是邻接矩阵， $\mathbf{D}$ 是度矩阵， $\mathbf{w}$ 是可学习参数。

$$\mathbf{g}_w \star \mathbf{x} = (\mathbf{D}^{-\frac{1}{2}}(\mathbf{A} + \mathbf{I}_N)\mathbf{D}^{-\frac{1}{2}})\mathbf{x}\mathbf{w} \quad (2-7)$$

此外，GCN 的兼容性极强，能够无缝融合到其他深度学习模型中，如循环神经网络 (RNN) 和长短期记忆网络 (LSTM)，以高效处理图中蕴含的序列信息。这种灵活性使得 GCN 成为应对各种图形问题的首选工具，能够适应多样的数据结构和应用场景。

简而言之，图卷积神经网络 GCN 是一个强大的工具，它利用深度学习技术来解析和理解图形数据的复杂结构。随着研究的深入和技术的发展，GCN 在交通流预测分析中的应用前景广阔。

2.6 元学习

元学习 (Meta-Learning)，是机器学习领域的一个重要分支，其核心目标是开发能够快速适应新任务的算法。这种算法通过跨任务学习，在有限标记数据的情况下揭示任务共性，增强模型对新任务的泛化能力。元学习的方法涵盖了多种策略，如模型无关的元学习，通过优化初始参数实现快速适应；基于记忆的策略，通过外部记忆组件存储跨任务经验；以及基于优化的方法，专注于调整学习过程以提高效率。

元图神经网络 (Meta-Graph Neural Networks) 是元学习与图神经网络的结合体，专门解决图数据中的小样本学习问题。通过挖掘图结构数据中的丰富关系信息，元图神经网络显著提升了模型在多样化数据上的泛化能力。在实际应用中，它已成功应用于社交网络分析、生物信息学、推荐系统等领域。例如，它能预测社交网络中信息的传播趋势，预测生物信息学中蛋白质的相互作用，以及提升推荐系统中的推荐准确性和个性化。

总体而言，作为机器学习领域的前沿技术，元学习通过优化学习过程，为模型提供了在少样本学习、强化学习等挑战性领域快速适应新任务的能力。随着研究的深入和技术的发展，元学习在未来将会有更加广阔的发展前景。

2.7 本章小结

时空序列数据通过其固有的时空关联性，为气象预测、交通运输和环境科学等领域的复杂动态系统预测模型提供了关键信息，从而显著提高了预测的深度和精确度。循环神经网络 (RNN)，尤其是长短期记忆网络 (LSTM) 和门控循环单元 (GRU)，利用其复杂的内部循环机制，特别适用于捕捉时空序列数据中的关键时间依赖性，这对于气象预测和交通运输等动态系统的序列预测任务至关重要。CNN 通过其卷积层、池化层和全连接层的协同作用，为图像识别和语音处理中的时空特征提取提供了创新性和高效率的方法，尤其在处理高维时空数据方面，如视频分析和遥感图像，展现了其在时空序列预测中的潜力。GCN 通过在图结构上直接操作，创新性地提取节点特征，为图结构时空数据分析中的节点分类和链路预测任务提供了有效的分析工具，这对于社交网络动态、交通网络和生物信息学中的复杂网络

分析至关重要。元学习通过跨任务学习揭示任务共性，显著增强了模型对新任务的泛化能力和快速适应性，尤其在小样本学习问题上，为时空序列预测任务提供了一种有效的学习策略。元图神经网络（**Meta-Graph Neural Networks**）融合了元学习与图神经网络的优势，尤其在图数据中的小样本学习问题上展现了卓越性能，为交通预测等领域提供了一种高效的预测工具。

3 基于动态学习图的客流量预测模型

地铁系统作为城市公共交通网络的关键组成部分，在满足市民日常通勤需求方面发挥着不可或缺的作用。当前，图卷积网络因其在提取交通数据空间特征方面的优势，已被广泛应用于地铁流量预测领域。然而，现有文献中的多数研究依赖于静态 GCN 模型，这些模型的邻接矩阵，包括基于路网结构、欧氏距离以及相似度等因素构建的图，通常是基于先验知识并通过手工方式预先设定的。这种方法不仅耗费大量时间和资源，而且在效率上存在明显不足，更重要的是，它限制了模型对地铁客流动态变化的捕捉和适应能力。因此，构建一种能够自适应地捕捉交通流量空间依赖性的动态 GCN 模型，对于提高预测精度和应对城市交通系统的复杂性与动态性具有重要的理论和实践价值。这种模型能够实时更新其邻接矩阵，以反映交通流量的即时变化，从而更准确地预测地铁流量，为城市交通管理和规划提供强有力的支持。

3.1 问题阐述与动态图学习模型构建

基于图结构的地铁客流量预测问题可任务可以总结如下：已知地铁网各个节点在最近过去 P 个时间步的交通量数值 $X = [x_{(t-p+1)}, \dots, x_{(t)}]$ ，预测从下一时间步开始的未来一段时间 Q 个时间步，路网各个节点的交通量数值 $Y = [x_{(t+1)}, \dots, x_{(t+q)}]$ ，其中 $x_{(t)} \in \mathbb{R}^{N \times d}$ ， N 为路网节点总数， d 是每个节点的流量维度， $f(\theta)$ 是需要学习的映射关系及参数， $\mathcal{G} = (\mathcal{V}, \mathcal{E}, A)$ ，其中 $\mathcal{V}$ 是表示交通序列的一组节点， $\mathcal{E}$ 是一组边， $A \in \mathbb{R}^{N \times N}$ 表示节点间依赖关系的邻接矩阵。该问题可用公式 (3-1) 形式化地表达：

$$\left[x_{(t-p+1)}, \dots, x_{(t)}; \mathcal{G} \right] \xrightarrow{f(\theta)} \left[x_{(t+1)}, \dots, x_{(t+q)} \right] \quad (3-1)$$

目前对于交通流量预测任务中广泛使用的图卷积神经网络模型，图构建方法可以分为：基于路网物理结构、基于相似性、基于自适应：

(1) 基于路网物理结构

基于路网拓扑的图通常是基于给定的站点拓扑结构构建的，例如道路物理连通网络。基于拓扑的图的邻接矩阵可以表示为：

$$a_{ij} = \begin{cases} 0, & \text{otherwise} \\ 1, & \text{if } ij \text{ connects} \end{cases} \quad (3-2)$$

其中 a_{ij} 表示邻接矩阵中的一个元素， v_i 是 v_j 图中的不同顶点。由于拓扑结构中

的连接可以是对称的，也可以是不对称的，因此基于拓扑的图可以是有向的，也可以是无向的。拓扑仅表示非欧几里得空间中的连接，因此基于拓扑的图是未加权的。此外，城市系统中的拓扑结构通常是固定的，因此可以将它们视为静态图。

还有一种是基于站点物理距离加权的图可以表示为：

$$a_{ij} = \begin{cases} 0, & \text{otherwise} \\ \frac{\exp(-d_{ij})}{\sigma} \end{cases} \quad (3-3)$$

其中 d_{ij} 是不同节点的物理距离。根据地理学原理，通常情况下，相邻物体间的相关性随着距离的减小而增强，而差异性随距离增加而增大。在缺乏预设拓扑结构时，构建基于距离的图，站点的物理距离越小，相似性越大。在多数应用中，邻接矩阵的元素是通过考虑距离的反比函数来计算的。

(2) 基于相似性

相似性可以从语义的角度提供对不同实体之间关系的见解。基于相似性的图可以基于时间序列的相似性来构建，例如兴趣点（POI）。在无法获得其他数据的情况下，通常基于时间序列的相似性构建基于相似性的图形。皮尔逊相关系数（Pearson Correlation）和 DTW（Dynamic Time Warping，动态时间规整）是用于计算时间序列之间相似性的两种常用方法。例如，由 DTW 计算的基于相似性的图的邻接矩阵定义见公式(3-4)：

$$a_{ij} = \exp(-DWT(X^i, X^j)) \quad (3-4)$$

(3) 基于自适应

基于自适应的邻接矩阵通过一个自适应图生成模块生成，用于自动推断数据中隐藏的相互依赖关系。该方法首先随机初始化一个可学习的节点 $E_A \in R^{N \times d_e}$ ，为所有节点嵌入字典，其中每行表示 E_A 一个节点的嵌入， d_e 表示节点嵌入的维度。然后，与通过节点相似性定义图类似，可以通过乘 E_A 以和 E_A^T 来推断每对节点之间的空间依赖关系：

$$a_{ij} = \text{softmax}(\text{ReLU}(E_i E_j^T)) \quad (3-5)$$

在训练过程中， E_A 会自动更新，学习不同流量序列之间的隐藏依赖关系，并获取图卷积的自适应矩阵。与基于距离等生成的静态邻接矩阵，学习得到的 E_A 的更能挖掘站点间的依赖关系，具有更好的预测能力。

现有基于图的预测模型往往依赖于手动定义的邻接矩阵，该过程需要依赖于距离、路网结构和兴趣点（POI）等外部数据。然而，这些数据的获取可能存在难度，并且通常需要经过复杂的预处理和手动构建。这一过程不仅耗时，而且需要整合多种外部数据源。此外，这些方法在本质上只能揭示静态的空间依赖关系，无法充分捕捉交通流量的动态变化。

尽管基于自适应的图构建方法在减少对预定义图依赖方面取得了一定进展，节省了手动构建的时间，但其在精确建模节点间随时间变化的时空异质性方面仍存在局限。这些方法往往只能捕捉到节点的静态特征，而无法有效反映节点间的动态交互和时间依赖性。




图 3-1 交通流量时空动态依赖性

Figure 3-1 Spatial and Temporal Dynamic Dependence of Traffic Volume

如图 3-1 所示，实线代表传统空间图中的连接；颜色代表链接的强弱；圆球是空间中三点；T1 和 T2 是相邻的两个时间步,交通网络中的节点连接关系会随着时间不断变化，呈现动态时空异质性。

因此，为了解决上述模型存在的问题，本章设计了一种基于动态时空依赖的交通流量预测算法。具体来说，本章提出了一种动态学习图模块，该模块采用创新的邻接矩阵构造方法。此方法能够动态生成并自适应调整权重，以反映每个时间步的邻接关系。这种方法克服了传统基于预定义邻接矩阵无法有效捕捉时间相似性模式的局限，显著提升了模型对交通流量动态变化的敏感性和预测精度，为动态网络分析提供了新的视角和工具。

3.2 动态图学习模型的架构与关键组件

在融合图卷积神经网络的空间处理和循环神经网络的时间序列分析能力的基础上，本文提出了一种动态时空依赖性预测模型。该模型通过结合最新的深度学习技术和优化算法，提高了预测的准确性和效率。模型以动态自适应图卷积为依托，通过学习每个时间步的节点空间关系，模型能够捕捉时变的空間相关性，并有效地聚合来自关键节点的信息，通过动态调整图卷积的参数来适应不断变化的交通流量模式。该框架在真实数据集上的性能评估中，显示出比现有方法更高的预测准确

率,例如,在平均绝对误差(MAE)和均方根误差(RMSE)等指标上均有显著降低。通过基于交通流量实时数据和历史趋势,模型采用自适应学习算法动态调整图卷积的参数,以优化预测性能。从而为交通流量的预测提供更为精确的解决方案,在短时交通流量场景下,模型能够提高预测的实时性和准确性。

图 3-1 为该模型的结构图。该模型主要由三部分组成,分别是邻接矩阵生成模块,空间特征提取模块以及时间特征提取模块。




图 3-2 动态图卷积模型架构图

Figure 3-2 Overall Architecture of Dynamic Graph Convolution

3.2.1 时间图生成模块

现有的基于 GCN 的流量预测模型,该模型需要预定义的相邻矩阵进行图卷积操作。现有工作主要利用距离函数或相似度量来预先计算节点邻近性。但是,预定义的图不能包含有关空间依赖性的完整信息,并且与预测任务没有直接关系,这可能会导致相当大的偏差。此外,如果没有适当的距离等先验知识,这些方法就无法适应其他领域,这使得现有的基于 GCN 的模型效果不强。

交通数据经常受到诸如时间、天气等条件的不规则的影响,交通网络上站点的客流量趋势可能会在一天中的同一时间发生变化。学习每个时间步的节点空间关系对于捕捉时变空间相关性和聚合来自适当节点的信息是必要的。因此本文设计了动态学习图生成模块,用于捕获节点之间的动态的空间相互依赖关系。具体做法是,使用与时间步相对应的嵌入矩阵 E_t 来构建每个时间点的学习图。 $E_t E_t^T$ 用于表示时间步 t 的学习图,这些矩阵通过 Softmax 函数进行标准化处理,确保了邻接矩阵的值总和为 1,从而实现了归一化。同时,ReLU 激活函数用于去除任何负值连

接,保证了网络的正向性。最终,这些嵌入矩阵 E 经过线性变换,生成了一个三维图 G ,其维度为 $P \times N \times N$,即 $G = G_1, G_2, \dots, G_p, G_t$ 表示时间步 t 时的节点间的关系, P 代表时间步的长度, N 表示图中节点的数量。这样的构图设计能够更精细地理解和分析节点关系随时间的演变,旨在精准地体现节点间的动态关系。本章定义的时间图 G_t 表示见公式(3-6):

$$G_t = \text{softmax}\left(\text{ReLU}\left(E_t E_t^T\right)\right) \quad (3-6)$$

3.2.2 动态图卷积模块

为了处理真实数据中的波动性和不确定性,图卷积操作在图信号处理中扮演着核心角色,其理论基础源于对图结构的数学描述—拉普拉斯矩阵。拉普拉斯矩阵不仅反映了图中节点间的连接关系,还在图神经网络中作为关键的算子,用于捕捉局部特征并进行信息传播。通过图卷积,可以有效地对图数据进行特征提取和分析,为复杂网络的研究提供了强大的工具,为处理大规模网络数据提供了强大的工具和理论支持。其一阶近似计算方式见公式(3-7),其中 A 代表图的邻接矩阵:

$$Z = (I_N + D^{-\frac{1}{2}} A D^{-\frac{1}{2}} X \Theta + b \quad (3-7)$$

这种新的方法,不是通过预定义邻接矩阵 A ,而是通过公式(3-6)动态生成,替换原始定义中的拉普拉斯矩阵,因此新的增强型图卷积 DGCN 可以表述为如下:

$$D^{-\frac{1}{2}} A D^{-\frac{1}{2}} = \text{softmax}\left(\text{ReLU}\left(G_t\right)\right) \quad (3-8)$$

$$Z = \left(I_N + \text{softmax}\left(\text{ReLU}\left(G_t\right)\right)\right) X \Theta + b \quad (3-9)$$

3.2.3 时间特征提取模块

除了空间相关性外,交通预测还涉及复杂的时间相关性。在这一部分中,实现了一个动态图卷积循环网络图卷积循环网络。在处理客流量序列时,考虑到参数量的精简和计算效率的提升,本文选择采用堆叠的 GRU 架构,其相对于 LSTM 具有显著的优势,即较少的参数和高效能,从而有效地提取出时间序列中的关键特征。同时,利用前面提出的 DGCN 替换 GRU 中的 MLP 线性层,以学习特定于节点的模式。其计算过程如下所示:

$$\tilde{A} = \text{softmax}\left(\text{ReLU}\left(G_t\right)\right) \quad (3-10)$$

$$z = \sigma\left(\tilde{A}\left[X_t, h_{t-1}\right] W_z + b_z\right) \quad (3-11)$$

$$r_t = \sigma\left(\tilde{A}\left[X_{:,t}, h_{t-1}\right] W_r + b_r\right) \quad (3-12)$$

$$\hat{h}_t = \tanh\left(\tilde{A}\left[X_{:,t}, r \odot h_{t-1}\right] W_{\hat{h}} + b_{\hat{h}}\right) \quad (3-13)$$

$$h_t = z \odot h_{t-1} + (1 - z) \odot \hat{h}_t \quad (3-14)$$

其中 X_t 和 h_t 是时间步 t 时间的输入和输出， z 分别 r 是复位门和更新门。 W_z 、 W_r 、 $W_{\hat{h}}$ 、 b_z 、 b_r 和 $b_{\hat{h}}$ 是模型中的可学习参数。与 GRU 类似，模型中的所有参数都可以通过随时间的反向传播进行端到端训练。输入序列通过图卷积网络在每个时间步动态地提取空间特征。这一过程不仅包括对节点间连接模式的深入学习，还涉及对节点特征的有效聚合。随后，这些提取的空间特征被进一步输入至门控循环单元（GRU）模型。GRU 模型通过其独特的门控机制，能够有效地捕捉并处理时间序列数据中的长期依赖性，进而提取出关键的时间特征。通过这种综合空间和时间特征的方法，模型能够对客流量序列进行精确的时空特征建模，这不仅增强了模型对复杂数据模式的理解能力，而且为后续的预测和分析工作提供了坚实的基础。

3.3 实验设置、数据分析与模型评估

3.3.1 实验环境与配置

本章构建了一个时空预测模型，利用 AutoDL 云服务平台强大的 GPU 算力进行高效计算。该模型基于 Python 3.8 和 PyTorch 1.8.1 版本进行实现。实验环境配置如下：计算平台采用了具有 12 核心的 Xeon(R) Platinum 8255C CPU，配备 40GB 内存，以及 NVIDIA RTX 2080 Ti 显卡，拥有 11GB 的显存。此外，系统环境为 Ubuntu 18.04，搭载了 CUDA 11.1，以支持高效的并行计算和深度学习模型训练。这样的硬件配置确保了模型能够快速处理大量数据，从而有效地提高了预测的准确性和效率。如表 3-1 所示：

表 3-1 实验平台配置信息

Table3-1 Description of dataset characteristics

配置项	配置值	配置项	配置值
CPU	Xeon(R) Platinum	Cuda 版本	11.1
内存	40GB	PyTorch	1.8.1
显卡	RTX 2080 Ti	Python	3.8
显存	11GB	操作系统	Ubuntu18.04

3.3.2 数据集描述与预处理方法

本文选取了 2019 年 1 月 1 日至 1 月 25 日期间，杭州市区地铁系统运营所产生的刷卡数据集作为研究对象。该数据集详尽记录了 25 天内的运营数据，覆盖了

3 条主要地铁线路及其沿线 80 个地铁站点的刷卡记录。数据集包含约 7000 万条刷卡记录，为城市交通流量的定量分析提供了丰富的原始数据资源，为理解城市交通模式和优化交通管理策略提供了实证基础。

数据集以压缩文件格式（zip）分发，以优化存储效率并便于数据传输。解压该压缩文件后，研究者将获得 25 个独立的 CSV 格式数据文件，每份文件均对应特定日历日的地铁刷卡数据。这种数据组织方式不仅提高了数据的可访问性，而且为逐日分析提供了便利，有助于研究者深入理解时间序列上的交通流量变化。

数据集的元数据详尽地记录了数据文件的命名规则、记录的刷卡事件数量、以及数据集的时间范围等关键信息，为数据的管理和分析提供了指导。原始数据集的字段信息详细列出了每条记录的特征，如表 3-2 所示，包括于时间戳、站点标识、刷卡次数等，为多维度的数据分析提供了可能。

表 3-2 地铁客流量数据字段信息

Table3-2 Metro Passenger Flow Data Field Information

列名	数据类型	说明	示例
time	String	刷卡时间	2019-01-01 10:00:30
lineId	String	地铁线路 id	C
stationId	int	站点 id	15
deviceId	int	刷卡设备 id	2992
status	int	进出站状态	1
userId	String	用户 Id	Adjjzkkz1555
payType	int	支付类型	0

在数据预处理阶段，鉴于 deviceId 和 payType 字段与研究内容不相关。同时由于夜间地铁客流量数据的稀疏特性，仅保留每日 05:30 至 23:30 时段的数据。为了验证模型的泛化性能，原始数据集按照 18:2:5 的比例划分为训练集、验证集和测试集，其中验证集用于训练模型，而测试集则作为模型性能的客观评价标准。窗口大小设定为 P+Q，其中前 P 步作为特征向量 X，后 Q 步作为预测目标 Y。为了提升数据的稳定性和一致性，对交通流量数据实施了 Z-Score 标准化处理，使训练过程更加稳定。归一化方法如公式(3-15)：

$$x = \frac{x - \mu}{\sigma} \tag{3-15}$$

其中 $\mu = \frac{1}{n} \sum_{i=1}^n x_i$ 为均值， $\sigma = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$ 为方差

该数据集的结构设计旨在便于数据的访问和分析，确保了数据的可追溯性和

一致性。通过对这些数据的深入分析,研究者能够洞察城市交通流量的模式、趋势以及潜在的优化机会。

3.3.3 评价指标与参数优化

(1) 评价指标

本文主要依据平均绝对误差、均方根误差和平均相对误差三个标准评估模型性能。鉴于地铁客流量预测是时空数据的连续回归任务,这些指标适合衡量预测的连续性,因此被选为评价标准。它们的定义如下:

MAE (平均绝对误差): 它是真值与预测值之差的平均值, 衡量绝对偏差。

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i^{real} - y_i^{pred}| \quad (3-16)$$

RMSE (均方根误差): 也被称为标准差, 它是真值与预测值误差平方的平均值, 类似标准差。

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i^{real} - y_i^{pred})^2} \quad (3-17)$$

MAPE (平均相对误差): 它是真值与预测值之差再除以真值之后取平均值, 反映相对误差。

$$MAPE = \frac{1}{n} \sum_{i=1}^n \frac{|y_i^{real} - y_i^{pred}|}{y_i^{real}} \quad (3-18)$$

(2) 参数设置

本章实验中, 采纳了上一节提出的融合动态图卷积神经网络的空间处理和循环神经网络的预测模型, 旨在利用一小时的历史地铁刷卡数据来预测未来一小时的交通流量。在样本构建过程中, 采用了 15 分钟为一个时间粒度, 这一选择基于对交通流量变化模式的分析, 以确保时间序列的粒度足够捕捉到关键的交通流量变化。通过滑动窗口方法, 将连续的 15 分钟时间序列数据划分为一个时间步。每个预测周期包括 4 个时间步的历史数据作为输入特征, 以及随后的 4 个时间步的数据作为预测的输出序列。这种方法允许捕捉短期内交通流量的动态变化, 为预测模型提供了丰富的时序信息。

在输入网络之前, 对输入数据和输出数据进行了归一化处理, 以确保数据的标准化和模型的收敛性。网络的所有权重参数采用 Xavier 初始化方法, 这种方法适用于深度网络, 因为它能够平衡各层的输入和输出方差, 从而减少梯度消失或爆炸的问题。实验中, 设置了批处理大小为 32, 嵌入维数为 10, 这些超参数的值是基于先前实验和网格搜索策略确定的, 以优化模型的训练效率和预测性能。以及初始

学习率为 0.001，学习率衰减比为 0.3。

为了优化模型参数并提高预测精度，本文采用了 Adam 优化算法，该算法因其自适应学习率调整而著称，能够有效地处理非稳定梯度的问题，加速模型的收敛。预测模型的性能通过最小化预测输出与实际观测值之间的平均绝对误差（Mean Absolute Error, MAE）来评估。选择 MAE 作为损失函数，是因为其对预测误差的绝对值敏感，有助于在具有高误差敏感性的任务中提高预测的准确性，特别是在交通流量预测中，MAE 能够更好地反映模型对实际流量变化的响应能力。

在模型评估过程中，遵循了标准的机器学习流程：首先使用训练集对模型进行训练，然后利用验证集来调整和确定模型的超参数。为了防止过拟合，采用了早停（early stopping）策略，即在验证集上的性能连续几个 epoch 没有显著提升时停止训练，以防止过拟合并节省计算资源。最终，在独立的测试集上对训练良好的模型进行评估，以验证其泛化能力。

3.3.4 实验结果展示与分析

(1) 对比实验

本文将提出的动态图卷积时空预测模型与若干经典交通流量预测方法进行了比较分析，结果如表 3-3 所示。通过对比实验，评估了动态图卷积模型在交通流量预测方面的性能，并与其他模型的表现进行了直接对比。实验结果表明，所提出的模型在预测精度上具有显著优势，验证了其在处理交通流量数据时空特性方面的有效性。

1) GRU：门控循环单元（Gate Recurrent Unit, GRU），专为解决传统循环神经网络在处理长序列数据时的梯度消失或爆炸问题而设计，该模型引入更新门和重置门机制，能够自适应地捕获长时间依赖关系。

2) LSTM：设计用于学习序列数据中的长期依赖关系。该模型通过引入三个门控机制输入门、遗忘门和输出门，来控制信息的流动，有效地解决了传统循环神经网络在处理长序列时遇到的梯度消失问题。

3) DCRNN^[29]：扩散卷积循环神经网络：数据驱动的交通流量预测，2018 年。模型通过将交通流视为有向图上的扩散过程，利用图上的双向随机游走来捕捉空间依赖性，并采用编码器-解码器结构结合预定采样技术来模拟时间依赖性。该模型有效地结合了空间和时间维度的信息，以提高交通流量预测的准确性，并在大规模真实交通数据集上表现出色。

4) Graph-WaveNet^[31]：用于深度时空图建模的图波网络，2019 年。一种创新的图神经网络架构，专门设计用于深度时空图建模。该模型通过自适应依赖矩阵和

堆叠扩张的一维卷积组件，能够精确捕捉数据中的隐藏空间依赖和长序列时间趋势。

5) AGCRN^[39]: 自适应图卷积循环网络，2020 年。此模型的独特之处在于它通过自适应更新图结构的方式来精准捕捉空间相关性。在交通网络等场景中，空间关系往往是动态变化的，AGCRN 能够根据数据的变化实时调整图结构，从而更好地反映实际的空间关联。同时，利用循环机制来处理时间序列数据的动态变化，这对于交通流量等随时间不断变化的数据类型来说至关重要。时间序列数据通常具有一定的趋势、周期性和随机性，循环机制可以有效地记忆历史信息，对当前状态进行更准确的预测。

6) PGCN^[66]: 渐进图卷积网络，2022 年。引入多尺度图卷积层，实现了图卷积参数的自适应调整。该模型依托图神经网络的空间感知力，精准捕捉交通网络中错综复杂的相互作用，同时融合时间序列分析，模拟交通流量的动态变化过程。这一方法不仅提升了预测的精确度，也增强了模型对不同交通情况的泛化能力。

7) RGSL^[46]: 基于语义知识的正则化图结构学习，2023 年。模型采用正则化图生成和拉普拉斯矩阵混合模块。这个模块将显式的先验结构与隐式结构巧妙地结合起来，实现对时间序列的准确预测。显式的先验结构可以提供一些已知的关系和规律，而隐式结构则能够捕捉到数据中的复杂模式和动态变化。两者的结合使得模型能够更好地适应不同的数据集和预测任务，提高模型的泛化能力。

表 3-3 模型对比实验结果

Table3-3 Results of model comparison experiments									
Model	15min			30min			60min		
	RMSE	MAE	MAPE	RMSE	MAE	MAPE	RMSE	MAE	MAPE
GRU	45.1	25.69	15.13%	45.26	25.93	15.35%	46.13	26.36	16.79%
LSTM	45.3	25.76	14.91%	45.52	26.01	15.10%	47.53	26.76	17.34%
DCRNN	40.39	23.76	14.00%	42.57	25.22	14.99%	46.26	26.97	16.19%
Graph-WaveNet	40.78	24.07	14.27%	42.8	25.48	15.23%	45.84	27.15	17.34%
AGCRN	41.90	24.13	14.63%	44.49	25.43	15.41%	46.82	26.68	16.22%
PGCN	44.15	24.21	14.61%	46.71	25.41	14.61%	47.31	25.81	16.16%
RGSL	42.85	24.83	14.28%	46.86	25.46	14.89%	47.13	26.89	16.31%
OURS	39.39	23.49	14.18%	41.21	24.26	14.67%	43.56	25.64	16.04%

从结果可以看出，本章节所提出的动态时空图网络模型，在多步时间序列预测任务中，其 MAPE、RMSE 及 MAE 指标的预测误差均实现了最小化，这一现象在多个时间步长上得到了一致的体现。与此相对，传统的 LSTM 和 GRU 模型在多项评价指标上均显示出较为明显的性能不足，从而验证了单纯依赖时间卷积神经网络进行交通流量预测的方法，并未能有效提升预测的准确性。Graph-WaveNet 和 AGCRN 模型，这两种均采用了自适应图结构的模型，均取得了较为显著的预测效果。此外，PVCGRN 模型，该模型通过整合多个静态融合图，亦在捕捉短期依赖性方面展现出了良好的性能。综上所述，本章提出的模型通过引入动态时空图网络的概念，进一步优化了预测精度，为交通流量预测领域提供了新的视角和解决方案。

(2) 消融实验

为验证模型中各个独立组件的功效，本文开展了消融研究。消融实验通过移除模型的单一组件，并据此构造简化版变体模型来进行。本文旨在通过分析这些变体模型在两个数据集上的表现，来评估各个组件对整体性能的具体贡献。各变体模型的命名及其构造细节如下所述：

- 1) 使用相似语义图,变体模型被命名为 dgcrn-sim
- 2) 使用嵌入图,变体模型被命名为 dgcrn-adapt
- 3) 使用动态时间图,变体模型被命名为 dgcrn-time

表 3-4 模型消融实验结果

Table3-4 Results of the model ablation experiments

Model	15min			30min			60min		
	RMSE	MAE	MAPE	RMSE	MAE	MAPE	RMSE	MAE	MAPE
dgcrn-sim	43.59	25.16	15.14%	47.19	27.35	16.43%	51.46	29.93	18.78%
dgcrn-adapt	40.87	23.85	14.24%	43.14	25.16	15.12%	46.54	26.76	16.44%
dgcrn- time	39.89	23.49	14.18%	41.21	24.26	14.67%	43.56	25.64	16.04%

消融实验结果，见表 3-4，揭示了动态时间图模型在各项评估指标上均优于其他变体，从而确认了模型组件的有效性。其中，DGCRN-Sim 变体在 RMSE、MAE 及 MAPE 上降低明显表明，静态图结构在表达空间依赖性方面存在局限。与此同时，自适应图结构模型的性能指标下降趋势，进一步证实了动态时间图在捕捉空间和时间依赖性方面的优势。这些结果共同突出了动态图卷积循环网络在交通流量预测中的高效性，尤其是在处理时空动态性方面的显著能力。

(3) 嵌入维度参数选择实验

为了增强模型在预测客流数据方面的精确度和效率，本文专注于对模型中的节点嵌入维度进行精确调整，结果如图所示。设计了一系列实验，测试了从 16 到 256 不同维度值的参数设置，使用平均绝对误差（MAE）作为衡量模型性能的标准。这一过程旨在深入分析不同维度对模型预测准确性的具体作用。实验结果显示，当节点嵌入维度设为 16 时，模型的预测效果最优。




图 3-3 节点嵌入维度结果图
Figure 3-3 Node Embedding Dimension Results

3.4 本章小结

在现代城市交通管理的学科领域内，对交通流量进行精确预测是实现交通系统优化和提升出行体验的关键因素。本章节深入探讨了一种基于动态时空依赖性的交通流量预测算法，该算法旨在对复杂的交通数据进行有效处理与深入分析。通过引入动态学习图模块，该算法不仅能够高效地计算节点间的相似度，还能随着时间的推移动态地构建邻接矩阵，以更精确地揭示交通流量的演变趋势。

动态学习图模块的核心优势在于其卓越的自适应能力，该能力使得模型能够在每个时间步学习并动态更新邻接矩阵。这种方法克服了传统方法中基于固定距离度量初始化邻接矩阵的局限性，这些传统方法往往难以捕捉交通流量随时间变化的复杂动态。相比之下，本章提出的方法通过动态更新邻接矩阵，能够更有效地捕捉并理解交通流量的时间相似性模式，生成的图结构能够更好地适应客流量的实时变化，为动态网络分析提供了创新的工具和视角。

此外，本算法通过构建的动态图对空间依赖性进行建模，并结合门控循环单元

来捕捉时间依赖性。GRU 作为一种高效的循环神经网络架构，特别擅长处理序列数据，尤其是在捕捉时间序列数据的长期依赖关系方面具有显著优势。通过将动态图与 GRU 相结合，本算法能够全面理解交通流量的时空特性，从而显著提高预测的准确性。

实验结果强有力地证实了本算法在地铁客运量预测方面的显著效果。与传统方法相比，本算法能够提供更为精确的预测结果，这对于实际的交通规划与管理具有重要的应用价值。

综合上述分析，本章节提出的基于动态时空依赖的交通流量预测算法在理论构建和实际应用两方面均展现出显著的潜力。通过这种算法的应用，可以更有效地理解和预测交通流量的动态变化，为城市交通规划和管理决策提供数据支持，进而推动智能交通系统的建设和发展。

4 融合周期特征和元学习的客流量预测模型

在对工作日交通流量进行细致分析的过程中,注意到不同时间段内的交通模式存在显著差异。这些差异不仅显现了交通流量的周期性特征,而且对于交通管理和规划具有重要的指导意义。然而,现有的交通流量预测模型在利用这些时间特征方面存在不足,尤其是在捕获周期性依赖方面的能力较弱。此外,这些模型在泛化到新的数据集时,往往表现出较低的适应性。鉴于此,本章提出采用元学习方法来提升模型的泛化能力。元学习学习是一种强大的机器学习范式,它通过利用未标记数据中的内在结构来学习特征表征,从而无需依赖大量标记数据。在交通流量预测的场景中,元学习学习可以通过分析交通数据的时空模式来学习有用的特征表征。为了进一步提升模型的时间依赖性捕获能力,引入日周期和周周期特征。这些周期特征能够帮助模型更好地理解 and 预测交通流量的周期性变化,从而在下游预测任务中实现更高的准确率。

4.1 客流量预测问题提出与建模

本章采用精细的定量分析方法对刷卡数据进行了深入探讨。通过构建流量变化趋势图,发现不同地铁站点的客流量数值及其波动曲线形态呈现出显著的异质性。这种差异性不仅揭示了各站点在客流量动态上的特定模式,而且为进一步理解地铁网络中的客流分布特征提供了重要视角。如图 4-1 所展示,这些趋势图直观地反映了各站点在不同时间段内的客流变化情况。

统计分析揭示了以下两个关键的观察结果:

(1) 早高峰时段与晚高峰时段的客流量存在显著差异。早高峰时段的客流量峰值较晚高峰时段更为显著,这一现象可能与工作日的通勤模式紧密相关。

(2) 每日的客流量变化呈现出双峰模式,即在一天中存在两个明显的流量高峰。通过观察地铁每日客流曲线图,发现每日的交通流量高峰期通常出现在早晨 8 点和傍晚 6 点,这与典型的上下班时间安排相吻合。

进一步分析表明,工作日的交通流量模式通常与固定的工作时间安排密切相关,而周末的模式则受到休闲活动安排的较大影响。例如,周末的交通流量峰值可能会出现在非传统高峰时段,这反映了人们参与购物、娱乐等活动的出行模式。在交通流量分析领域,不同时间段间的显著交通模式差异是一个重要且不可忽视的现象。该议题不仅涉及交通流量的量化分析,还涵盖了交通管理策略和城市规划的深入探讨。通过比较工作日与周末的交通数据,可以揭示出行为模式的多样性和动态变

化,为优化城市交通系统提供了科学依据。这些差异强调了在设计交通模型时考虑时间维度的重要性,包括一天中的具体时段和一周中的特定日子。将时间周期性特征融入交通模型设计中,不仅能增强模型对交通流量和模式变化的预测能力,提升城市交通系统的整体效率,还能确保模型在动态变化的环境中迅速适应,准确预测交通流量和模式。




图 4-1 站点一天流量变化趋势图

Figure 4-1 One-day traffic flow trend of the station

尽管引入周期性特征在提升模型预测能力方面具有优势,现有模型在处理新数据时仍常面临泛化能力不足的问题。传统的周期性特征提取方法多依赖递归神经网络(RNN)或卷积神经网络(CNN),这些方法在应对动态变化的交通模式时效果有限。此外,当前的图神经模型在处理复杂交通数据时,通常依赖复杂的时空图神经网络方法,导致计算效率低下。

为解决这些问题,本文引入了图元学习,特别是对比学习这一元学习的分支。元学习通过对比不同数据样本以优化特征表示,从而增强时空图学习能力,并提升下游预测任务的准确性。通过将日周期、周周期信息编码为模型可以学习的特征,并引入图元学习方法,本文设计出一种更高效且有效的模型,减少对复杂时空图神经网络的依赖,进而提高模型的性能和效率。

本文的关键创新在于图元学习与周期特征融合模块。该模块将图元学习技术与时间周期性特征结合,具体包括:利用时间嵌入方法为每个时间步添加时空身份信息^[67],从而解决样本在空间和时间维度上的不可区分性问题。元学习作为无监督特征学习的方法,通过预测图结构中的缺失信息来优化节点或边的表示,并结合对比学习提升特征区分能力。在实际应用中,该模块能够有效理解和处理复杂数据结构,提升模型对交通流量和模式变化的预测能力。例如,在处理不同时间段的交

通流量差异时，该模块能够准确捕捉时间周期性特征，同时借助图元学习机制快速适应新数据，为城市交通系统的可持续发展和智能化管理提供强有力的支持

4.2 客流量预测融合模型框架

该模型主要由三部分组成，如图 4-2，分别是时间嵌入模块模块，元学习学习模块以及编码器-解码器模块。本文提出的图元学习与周期特征融合模块旨在解决现有方法在面对周期性变化时的局限性。图元学习与周期特征融合模块的具体实现包括：（1）将周期性特征通过时间嵌入方法整合到图神经网络中；（2）利用元学习的对比学习机制进一步优化特征表示，提升模型对不同交通模式的识别能力。通过这些技术手段，本模块能够在处理周期性交通流量数据时，显著提高预测精度，并具备较强的泛化能力。下面将一一详细介绍时空块各个组件和转换层的具体设计和功能。




图 4-2 模型架构图

Figure 4-2 Model architecture diagram

4.2.1 周期特征提取与嵌入

为了更好地捕捉时间序列数据中的时间周期特性，利用两个时间嵌入矩阵 $TiD(time\ at\ day\ index)$ 和 $DiW(day\ at\ week\ index)$ 得到每个时间步的嵌入信息，需要将它们与时间序列数据结合起来^[67]。以下是具体步骤：

(1) 定义时间嵌入矩阵

$TiD \in R^{T_d \times d}$ 表示一天中的时间嵌入矩阵，其中 T_d 是一天中的时间槽数量（例如，一天 24 小时，每小时一个时间槽，则 $T_d=24$ ）， d 是隐藏维度。 $DiW \in R^{T_w \times d}$ 表示一周中的时间嵌入矩阵，其中 T_w 是一周中的天数（通常 $T_w = 7$ ）， d 是隐藏维度。本章中由于一周为 7 天，每天有 73 个时间步，所以， $T_w=7$ ， $T_d = 73$ 。

(2) 获取时间步的索引

假设有一个时间序列数据 $X \in \mathbb{R}^{N \times T}$ ，其中 N 是变量的数量， T 是时间槽的数量。对于每个时间步 t ，需要获取其在一天中的时间索引和在一周中的时间索引。 t_{day} 表示时间步 t 在一天中的时间索引，范围为 $[0, T_d - 1]$ 。 t_{week} 表示时间步 t 在一周中的时间索引，范围为 $[0, T_w - 1]$ 。

(3) 获取时间步的嵌入信息

对于每个时间步 t ，可以从时间嵌入矩阵中获取对应的嵌入信息：从 TiD 中获取一天中的时间嵌入，如公式(4-1)所示：

$$\text{embedding}_{day}(t) = TiD[t_{day}] \quad (4-1)$$

从 DiW 中获取一周中的时间嵌入，如公式(4-2)所示：

$$\text{embedding}_{week}(t) = DiW[t_{week}] \quad (4-2)$$

(4) 结合嵌入信息

将这两个嵌入信息结合起来，得到每个时间步的最终嵌入信息见公式(4-3)，其中， $\parallel$ 表示向量连接操作。最后，把得到时间嵌入向量输入到预测层。

$$\text{embedding}(t) = \text{embedding}_{day}(t) \parallel \text{embedding}_{week}(t) \quad (4-3)$$

4.2.2 元学习增强模块

(1) 元图结构学习

在元图结构学习中，节点的初始化是通过 E 来实现的。该矩阵 E 作为图节点的初始特征嵌入，为后续自适应图结构的构建提供了必要的起点。自适应图结构的动态调整能力，是通过学习过程中对节点间连接权重的优化来实现的，这使得学习器能够根据数据的内在结构和学习任务的特定需求，灵活地调整图的拓扑特性。这种自适应性是元图学习器在处理复杂图数据时的关键优势，它增强了模型对数据多样性和动态性的适应能力。

$$g = \text{softmax}(\text{relu}(EE^T)) \quad (4-4)$$

(2) 图卷积操作

采用了基于切比雪夫（Chebyshev）多项式的近似技术来实现图卷积操作。该

技术允许图卷积网络在图结构上有效地进行局部特征聚合,通过利用 Chebyshev 多项式的正交性质,对节点的局部邻域特征进行紧凑的表示和处理。具体地, Chebyshev 多项式近似方法通过在图卷积层中应用相同的多项式系数,实现了参数共享,这不仅增强了模型对不同节点间相似性的泛化能力,也显著减少了模型的参数规模。

在本章中,输入数据包括随机生成的特征矩阵以及节点流量数据,这些数据为模型提供了丰富的局部和全局信息,使得模型能够更准确地捕捉和学习图结构上的复杂模式。

(3) 元图学习器

传统的图卷积网络 (GCN) 通常依赖于预先定义的图结构,这些结构可能无法充分反映交通流的动态变化。为了解决这一问题,元图学习器提出了一种基于记忆网络的图结构学习框架,该框架能够自适应地调整图结构以更好地匹配实际交通状况。元图学习器的组成如下:

1) 元节点库: 作为记忆基础,由一组预定义的原型向量 Φ 组成,每个向量编码了交通网络中的特定时空模式。这些原型向量是通过无监督学习从历史数据中提取的,能够代表交通流的典型变化趋势。

2) 查询向量生成器: 对于每个节点,模型利用编码器输出的隐藏状态 H_t ,通过投影向量 W_Q 映射成一个查询向量 Q_t 。该查询向量用于在元节点库中检索与当前状态最相关的原型。

3) 记忆检索机制: 通过计算查询向量与元节点库中每个原型的相似度 a ,模型采用归一化方法确定每个原型对当前节点嵌入的贡献度。

4) 节点特征表示: 网络根据记忆检索过程中相似度和元节点向量得到的加权向量,生成当前节点的嵌入表示,从而实现对节点特征的动态表征 M_t 。

5) 记忆参数优化 (Memory Parameter Optimization): 通过引入对比损失和一致性损失等约束条件,模型优化元节点库中的记忆参数,增强对不同交通模式的区分能力。

$$Q_t^{(i)} = H_t^{(i)} * W_Q + b_Q \quad (4-5)$$

$$a_j^{(i)} = \frac{\exp(Q_t^{(i)} * \Phi^T[j])}{\sum_{j=1}^{\phi} \exp(Q_t^{(i)} * \Phi^T[j])} \quad (4-6)$$

$$M_t^{(i)} = \sum_{j=1}^{\phi} a_j^{(i)} * \Phi[j] \quad (4-7)$$

综上所述,元图学习 (Meta-Graph Learner) 通过其独特的组成和功能,为交通预测模型提供了一种新颖的记忆增强机制,使其能够更有效地捕捉和预测复杂的时空依赖性,同时提高了模型的泛化能力和鲁棒性。这种基于记忆网络的图结构

学习方法,为理解和预测交通流中的复杂动态提供了一种新的视角,并为相关领域的研究开辟了新的可能性。

(4) 对比损失

损失函数是衡量模型预测与实际观测之间差异的关键工具,用于指导模型训练过程中的参数优化。对比损失(Contrastive Loss)和一致性损失(Consistency Loss)是两种特殊的损失函数,它们在训练具有记忆增强特性的模型,发挥着重要作用。

对比损失是一种用于学习相似性度量的学习目标,它鼓励模型将相似的样本映射到接近的点,同时将不相似的样本映射到远离的点。对比损失和一致性损失可以定义为:

$$\mathcal{L}_1 = \sum_t^T \sum_i^N \max\{\|Q_t^{(i)} - \Phi[p]\|^2 - \|Q_t^{(i)} - \Phi[q]\|^2, 0\} \quad (4-8)$$

$$\mathcal{L}_2 = \sum_t^T \sum_i^N \|Q_t^{(i)} - \Phi[p]\|^2 \quad (4-9)$$

其中 T 表示训练集中序列(即样本)的总数,并表示 p, q 在给定的本地化查询的公式 4-6 中排名前两个内存项的索引。通过实现这两个约束,将最相似的原型 $Q_t^{(i)}$ 、 $\Phi[p]$ 视为正样本,将第二个相似的原型 $\Phi[q]$ 视为负样本(表示正负对之间的边距)。

对比损失和一致性损失,为模型提供了一种结构化的学习方式,使其能够更好地理解和记忆交通数据中的时空模式。对比损失通过区分不同交通模式的相似性,帮助模型学习到更加丰富和区分性的特征表示。一致性损失则确保了模型在时间序列上的预测是平滑和连贯的,从而提高了模型对交通流动态变化的适应性和鲁棒性。这两种损失函数的综合使用,增强了模型的记忆能力和泛化能力,使其在复杂的交通预测任务中表现出色。

4.2.3 编码器-解码器框架

在序列转换任务中,编码器-解码器模型扮演着至关重要的角色。编码器部分通过一系列复杂的变换,将输入序列映射到一个高维空间中的紧凑表示,该表示能够捕捉输入数据的核心特征和语义信息。这一过程通常涉及非线性变换和特征抽象,以确保能够充分理解输入数据的结构和内容。随后,解码器部分利用编码器生成的上下文向量作为初始状态,通过逐步生成的方式构建输出序列。解码器的设计通常基于循环神经网络门控循环单元(Gated Recurrent Units, GRUs),这些网络结

构能够处理序列数据的时间依赖性。

因此，本章编码器-解码器结构通过紧密集成图卷积网络和递归神经网络的优势，辅以元学习学习的记忆增强机制，为预测提供了一种强大的建模工具。这种结构不仅提高了模型对时空数据动态性的适应能力，也显著增强了其预测精度和泛化性能。

4.2.4 周期特征与元学习融合机制

编码器-解码器架构，作为深度学习领域的一种先进模型，以其在序列到序列任务中的卓越表现而备受推崇。该架构通过精心设计的编码器和解码器模块，能够有效捕捉输入数据的长期依赖性，从而在复杂序列分析中展现出卓越的性能。进一步地，将时间周期性特征整合入该架构中，显著提升了模型对交通流量数据内在短期依赖性和周期性模式的捕捉能力。这种创新的融合策略，不仅显著增强了模型对交通流量动态变化的预测精度，而且显著提高了预测结果的准确性和可靠性，为交通流量预测领域提供了一种高效且精确的解决方案。

综上所述，将时间周期性特征整合到编码器-解码器框架中，为交通流量预测和城市交通系统优化提供了一种有效的解决方案。

4.3 实验设计、数据分析与模型评估

4.3.1 实验环境与配置

利用 AutoDL 云服务平台强大的 GPU 算力进行高效计算。该模型基于 Python 3.8 和 PyTorch 1.8.1 版本进行实现。实验环境配置如下：计算平台采用了具有 12 核心的 Xeon(R) Platinum 8255C CPU，配备 40GB 内存，以及 NVIDIA RTX 2080 Ti 显卡，拥有 11GB 的显存。此外，系统环境为 Ubuntu 18.04，搭载了 CUDA 11.1，以支持高效的并行计算和深度学习模型训练。

4.3.2 数据集

杭州地铁数据集数据集：包含杭州市区 2019 年 1 月 1 日至 1 月 25 日期间共 25 天地铁刷卡数据记录，共涉及 3 条线路 80 个地铁站约 7000 万条数据，同 3.3.2。

4.3.3 评价指标、参数设置

(1) 评价指标

本文主要依据 RMSE、MAE 和 MAPE 三个标准评估模型性能。鉴于地铁客流量预测是时空数据的连续回归任务，这些指标适合衡量预测的连续性，因此被选为评价标准。它们的定义如下：

MAE（平均绝对误差）：它是真值与预测值之差的平均值，衡量绝对偏差。

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i^{real} - y_i^{pred}| \quad (4-10)$$

RMSE（均方根误差）：也被称为标准差，它是真值与预测值误差平方的平均值，类似标准差。

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i^{real} - y_i^{pred})^2} \quad (4-11)$$

MAPE（平均相对误差）：它是真值与预测值之差再除以真值之后取平均值，反映相对误差。

$$MAPE = \frac{1}{n} \sum_{i=1}^n \frac{|y_i^{real} - y_i^{pred}|}{y_i^{real}} \quad (4-12)$$

(2) 参数设置

本章实验中，实验利用了连续一小时的历史数据集，旨在预测紧随其后的相同时间段内的数值。数据被划分为 15 分钟的时间步长，从而形成了由四个连续时间步长组成的输入序列，以及随后的四个时间步长构成的输出序列。在输入至预测模型之前，对输入数据和输出数据执行了归一化处理，以确保数据的标准化。所有层的自定义学习参数均由 Xavier 初始化；批处理大小设置为 32；嵌入维数设置为 128；初始学习率为 0.01，衰减比为 0.1。

为了优化模型参数，选择了 Adam 优化算法，并结合平均绝对误差 MAE 损失函数来最小化预测输出与实际观测值之间的差异。为了进一步引入对比损失和一致性损失以优化模型参数，以增强模型在不同时空模式下的区分能力。这一损失函数的采用显著提高了预测精度，提高模型对不同时空模式的区分能力来进行。

在模型评估阶段，遵循了标准的机器学习流程，包括使用训练集进行模型训练，利用验证集进行超参数的调整，以及在测试集上对经过充分训练的模型进行最终评估。这一流程确保了模型的泛化能力，并能对模型性能进行全面的量化分析。

4.3.4 实验结果展示与分析

(1) 对比实验

本文将提出的动态图卷积时空预测模型与若干经典交通流量预测方法进行了比较分析,结果如表 4-1 所示。通过对比实验,评估了元学习、周期特征模型在交通流量预测方面的性能,并与其他模型的表现进行了直接对比。实验结果表明,所提出的模型在预测精度上具有显著优势,验证了其在处理交通流量数据时空特性方面的有效性。

1) GTS^[44]: 基于离散图结构的时间序列预测,2021 年。提出了一种离散图结构学习方法,用于建模和预测多时间序列数据。能够识别和量化时间序列中的隐含结构,进而在预测过程中实现更深层次的特征提取和信息融合。

2) PVGCN^[55]: 铁客流量预测的物理-虚拟协同建,2020 年。模型通过构建物理图和虚拟图来捕捉车站间的复杂空间和时间依赖性。物理图基于地铁系统的实际拓扑结构构建,而虚拟图则根据车站间乘客流量的相似性和相关性构建,以探索车站间的隐含联系。将这些图信息集成到图卷积门控循环单元中,以学习空间-时间表示。这种表示既包含了地铁系统的实际空间结构信息,又融入了基于乘客流量相似性和相关性的隐含关系信息,从而为准确预测地铁客流量提供了有力支持。

3) MegaCRN^[65]: 时空元图学习在交通预测中的应用,2023 年。采用了图卷积网络来提取交通数据的空间特征,并结合循环神经网络捕捉时间序列的动态特性。引入了一种元学习机制,使模型能够快速适应新的交通场景,提高了预测的准确性和鲁棒性。MegaCRN 模型通过融合图卷积网络(GCN)与循环神经网络(RNN)的优势,有效地捕捉了交通数据的空间特征和时间序列的动态特性。此外,该模型引入了元学习机制,显著提升了模型对新交通场景的快速适应能力,从而增强了预测的准确性与鲁棒性。

在本章节提出的客流量预测模型中,融合了周期性特征与元学习机制,展现了在多步时间序列预测任务中的卓越性能。该模型在平均绝对百分比误差(MAPE)、均方根误差(RMSE)及平均绝对误差(MAE)等关键评价指标上实现了误差的最小化,且这一优势在不同时间步长上得到了一致验证。相对而言,RGSL、GTS、PGCN 等模型在多个评价指标上表现不佳,凸显了传统方法在时空图卷积网络基础上进行交通流量预测的局限性。MegaCRN 模型,借助元图学习策略,显著提升了预测精度。本章所提出的模型通过整合元学习与周期特征嵌入,有效增强了模型的泛化能力,并进一步增强了对流量的日周期、周周期的捕捉,学习了站点的日周期、周周期的特征表示,可对基于 RNN 等模型短期序列建模能力的提升,为站点流量预测领域带来了创新的视角与解决方案。

表 4-1 对比实验

Table4-1 Results of model comparison experiments

Model	15min			30min			60min		
	RMSE	MAE	MAPE	RMSE	MAE	MAPE	RMSE	MAE	MAPE
GTS	45.85	23.83	14.21%	46.79	25.32	14.58%	47.56	26.39	15.29%
PVCGN	39.42	23.69	14.74%	41.78	24.62	14.61%	46.10	26.84	16.90%
MegaCRN	39.21	22.95	14.18%	40.36	23.78	14.46%	42.39	24.56	15.12%
OURS	38.24	22.89	13.96%	39.36	23.59	14.24%	40.51	24.23	14.92%

(2) 消融实验

通过细致的消融实验，旨在深入探究 STMCR 模型中各个组件的功能和重要性。实验过程中，模型的不同模块被逐一移除或修改，以评估其对整体性能的影响。具体的消融策略包括：

1) 移除元学习学习机制：模型命名为 STMCRN-M，在该配置中，模型的元节点库及其相应的对比损失被去除，以评估元学习学习在模型中的作用。

2) 不采用周周期时间嵌入：模型命名为 STMCRN-WEEK，在此设置下，模型未引入周周期性的时间嵌入，从而可以分析周周期性特征对模型性能的贡献。

3) 不采用日周期时间嵌入：模型命名为 STMCRN-DAY，与周周期实验类似，此配置中模型未考虑日周期性的时间嵌入，以探究日周期性特征对预测结果的影响。

表 4-2 消融实验结果

Table4-2 Results of ablation experiments

Model	15min			30min			60min		
	RMSE	MAE	MAPE	RMSE	MAE	MAPE	RMSE	MAE	MAPE
STMCRN-M	59.25	31.68	17.48%	63.36	34.56	19.75%	72.32	38.97	23.24%
STMCRN-WEEK	38.29	23.12	14.12%	40.03	23.87	14.55%	41.31	24.62	15.67%
STMCRN-DAY	46.07	26.94	15.77%	49.78	28.87	16.47%	56.03	31.73	18.16%
STMCRN	38.24	22.89	13.96%	39.36	23.59	14.24%	40.51	24.23	15.42%

表 4-2 展示了消融实验的结果。分析表明，融合元学习学习机制与周期性时间特征嵌入的模型在预测准确性方面表现卓越。该结果明确证实了元学习学习与周期性特征嵌入在捕捉地铁客流的时间依赖性方面具有显著效能，能够精确识别并利用数据中隐含的模式和特征。

特别地，不采用周周期时间嵌入的模型在预测精度上显著低于其他配置，这表明周周期特征在客流量变化中扮演着关键角色。周周期性特征的引入能够显著提升模型对不同时间段客流量变化的捕捉能力，从而提高预测的准确性。此外，日周期时间嵌入对模型预测性能的提升作用也得到了验证，进一步增强了模型对一周内客流量变化的捕捉能力。这一结果进一步强调了在时间序列预测模型中考虑时间周期性特征的重要性。

消融实验的结果强调了在构建地铁客流量预测模型时，纳入时间嵌入特征的重要性。这些发现为未来在相似时间序列预测任务中模型设计的优化提供了坚实的实证基础，并对提升预测模型的泛化能力和精确度具有指导意义。

(3) 超参数选择实验




图 4-3 节点嵌入维度实验

Figure 4-3 Node Embedding Dimension Experiment

为了提升模型在客流数据预测任务中的性能和准确性，本文对模型架构中的关键参数—嵌入层的维度进行了细致的调优。参数调优的实验设计采用了一系列的维度值（16、32、64、128、256），这些值是基于先前研究和理论分析选择的，以确保能够全面评估不同维度设置对模型性能的影响。采用平均绝对误差（MAE）作为性能评估指标，因为 MAE 能够直接反映预测值与实际值之间的平均误差，这

对于客流数据预测任务来说是一个直观且重要的度量。实验通过对比不同维度设置下的 MAE，结合统计测试和误差分析，来评估和比较模型性能的变化，以深入探究不同维度设置对模型预测能力的具体影响。

通过一系列的实验和对比分析，如图 4-3 所示，当嵌入维度设置为 128 时，模型在预测任务上达到了最低的 MAE 值。这一结果表明，128 维的嵌入空间为模型提供了足够的灵活性来捕捉客流数据中的复杂模式和动态变化，同时避免了过高维度带来的过拟合风险和计算资源的浪费。

4.4 本章小结

在城市交通研究领域，模型的泛化能力是其有效性的关键指标；同时，对工作日与周末交通模式的对比分析是研究中不可或缺的一环。这些模式的异质性不仅映射了居民在不同生活节奏下的出行行为，而且深刻地揭示了交通流量模式与日常生活活动之间的内在联系。工作日的交通流量显著受到工作时间安排的影响，而周末则主要受到休闲和家庭活动的驱动。因此，在交通模型的构建过程中，必须致力于提升模型的泛化能力，并对时间维度的复杂性进行深入分析，尤其是对每日不同时间段和每周特定日子的动态变化。

本文探讨了元学习技术在提升交通流量预测模型泛化能力方面的潜力。作为一种前沿的机器学习策略，元学习能够从数据中提取关键特征，并利用对比损失机制增强这些特征的表达力，这对于深入理解复杂的时空模式至关重要。通过整合日周期和周周期等周期性特征，本文提出的模型能够更精确地识别并预测短期时间依赖性，从而在预测未来交通流量方面展现出卓越的性能。

综合本文的发现，通过将元学习技术与周期性特征相结合，显著提高了交通流量预测的准确性和适应性。这种方法不仅加深了对交通流量动态变化的理解，而且为城市交通管理和规划提供了新的视角和重要的参考价值。

5 地铁客流量分析平台的设计与实现

在当前的地铁运营管理中，传统的关系数据库系统已无法满足大规模客流量数据处理和实时分析的需求，尤其是在处理时序数据和快速响应查询方面。因此，本文设计并构建了一个地铁客流量智能分析与可视化管理平台。该平台的主要功能是高效整合和管理地铁运营过程中产生的数据，包括实时监控、历史记录和时间段内数据的聚合统计，以及预测模型的输出数据。通过数据检索功能，运营人员可以即时获取所需信息。

此平台的一个显著特点是其集成的预测算法集成的预测算法，能通过对过往数据的深度挖掘准确预测未来客流状况，并以直观易懂的图表形式展示，为运营决策提供有力支持。此外，平台采用了前后端分离架构，前端采用 Element UI 框架构建，确保了用户界面的友好性和互动性；后端则采用 Java 和 Spring Boot 技术，保证了服务的稳定性和效率。同时，平台采用了 Redis 和 MySQL 数据库技术的组合，以优化数据的读写性能，保证系统响应速度和数据处理能力。特别是通过集成 Redis TimeSeries 这一开源时间序列数据库扩展模块，平台实现了对客流量数据的高效聚合查询。

这一架构设计显著提升了地铁运营管理的效率，更进一步推动客流量数据分析的精确度与实时性，为运营策略的优化和资源的高效配置提供了技术支撑。

5.1 地铁客流量分析平台需求分析

（1）数据可视化显示

在现代地铁运营管理中，深入理解和分析复杂的客流量动态至关重要。为此，本文开发了一个高效的数据可视化模块。该模块运用了先进的图形化技术，例如折线图和柱状图，直观地展示了各个站点的客流量变化趋势，使得非专业人士也能轻松解读数据。通过将复杂的统计数字转化为色彩鲜明、易于解读的视觉元素，显著降低了用户操作的复杂性，并提升了用户界面的友好度和交互体验。此外，便捷的查询功能和实时更新的可视化数据，使得运营人员能够迅速做出决策，优化运营策略，提高整体运营效率。

（2）用户与权限管理

在数据系统架构中，用户权限管理至关重要，犹如数据安全与完整性的守护者。该机制首先确保用户身份的准确识别与验证，通过严格的认证流程，确保只有合法用户能够接入系统。其核心在于设计精细的权限策略，对用户访问和操作数据资源

进行严格控制。通过细致的权限划分,如赋予管理员全面的数据管理权限,包括数据的上传、修改和删除,而普通用户则仅限于数据的查阅和查询,这种差异化管理策略有效防止了未经授权的数据访问和潜在的数据泄露风险。这样的设计不仅维护了数据的机密性,还提高了系统的整体效率 and 管理的灵活性。

(3) 热点站点排行

在热点站点排行模块中,实现了对全城市地铁站点的深度洞察,通过精确的实时数据采集,对每个站点的用户流量进行详尽的统计和分析。这一模块不仅关注总体趋势,还提供细致的站点级数据,如每日、每周或每月的进出站频次,以便于运营团队全面了解各站点的活跃度和使用模式。更重要的是,模块内嵌有智能排序功能,可以根据用户流量、进出站时间分布等多维度指标,灵活调整排序,使得运营人员能够快速定位出热门站点和潜在问题站点,从而制定更精准的运营策略和优化方案。这样的设计,极大地提升了运营决策的科学性和效率。

(4) 聚合统计

在聚合统计模块中,设计了一套精密的数据处理流程。首先,它能够对用户的进出站行为进行详尽的记录,包括精确的时间戳、站点信息以及用户身份等关键数据。通过实时数据采集,模块能够捕捉到用户在不同时间段的动态行为模式。接着,这些数据经过精心的整合和清洗,被转化为便于分析的结构化格式,支持灵活的时间窗口划分,如按小时、日、周或月等,进行深度的聚合统计分析。这种功能不仅有助于揭示用户行为的规律性,如早晚高峰期的流量变化,还为以进行深入的数据挖掘和分析,进而为模型训练和预测提供数据支撑。通过数据的深度分析,还可以发现潜在的用户行为趋势,为优化地铁运营策略、提升乘客体验提供科学依据。

5.2 地铁客流量分析平台系统设计

本章开发的地铁客流量分析平台,前端采用 Vue.js 框架与 Element UI 库构建,后端基于 SpringBoot 框架实现,结合 MySQL 数据库与 Redis 缓存进行数据存储与高效处理。平台利用 MyBatis 作为对象关系映射(Object-Relational Mapping, ORM)工具,优化数据访问层,提高数据处理效率。此外,引入 Redis TimeSeries 模块,专门处理时间序列数据,支持复杂查询与聚合操作,以满足实时数据分析需求。该平台的设计充分考虑了现代软件开发的效率与性能要求,为地铁客流分析提供了一个强大而灵活的技术解决方案。

5.2.1 地铁客流量分析平台相关软件技术

本平台的前端界面基于 Vue 框架, 并采用 Element UI 可视化库构建。后端功能实现依赖于 SpringBoot 框架。此外, 平台利用 MySQL 数据库进行数据持久化存储, 并结合 Redis 缓存和 Redis TimeSeries 进行时间序列数据的窗口聚合计算。同时, MyBatis 与 MySQL 作为数据持久化的中间件, 进一步优化了数据处理流程。

Element UI 是一个基于 Vue 的组件库, 旨在为开发者和设计师提供一套完整的 UI 工具集。该库遵循严格的设计准则, 确保产品逻辑的合理性和易用性。通过提供封装良好的代码组件, Element UI 显著提高了开发效率, 并支持在线主题定制, 以满足个性化的视觉需求。此外, Element UI 还提供了丰富的设计资源, 帮助用户快速构建原型或视觉草图, 进一步加速设计流程。

SpringBoot 是一个开源框架, 旨在简化创建基于 Spring 的应用程序的过程。它允许开发者快速构建独立的、生产级别的 Spring 应用程序。通过提供一系列大型项目常用的默认配置, SpringBoot 使得项目启动和运行变得更加快捷。此外, 它还支持微服务架构, 这是现代软件开发中的一个重要趋势。总之, SpringBoot 提供了一个快速、便捷的方式来开发 Spring 应用程序, 使得开发者能够专注于业务逻辑的实现, 而不是配置的细节。

Redis TimeSeries 是一个开源时间序列数据库的扩展模块, 专门为 Redis 环境设计, 旨在提供高效能与易用性。该模块支持复杂的查询语言, 使用户能够高效地进行时间序列数据的存储、更新及查询操作。得益于 Redis 在内存处理方面的优势, Redis TimeSeries 实现了高速的数据插入操作和低延迟的数据读取, 同时支持包括最小值、最大值、平均值、总和、范围和计数在内的多种聚合查询功能。此外, 它提供了时间序列数据的二级索引和标签系统(键值对), 允许用户基于标签进行查询, 从而优化了对时间敏感数据的处理。Redis TimeSeries 的模块化设计也保证了它能够无缝地集成进现有的 Redis 部署中, 为用户提供一个功能强大且灵活的时间序列数据管理方案。

MySQL 作为一种领先的开源关系型数据库管理系统(RDBMS), 因其卓越的性能、高度的可靠性以及用户友好性而广受推崇。该系统提供了多语言编程接口(API), 从而实现了与多种应用程序的无缝集成。其独特的存储引擎架构设计, 赋予了数据库管理员根据特定的业务需求来调整和优化数据库性能的能力, 涵盖了事务处理、并发控制以及全文搜索等关键领域。安全性方面, MySQL 通过加密连接和精细的访问控制机制, 提供了强有力的数据保护。随着数据处理需求的日益增长和复杂化, MySQL 持续在易用性、扩展性和性能优化方面进行创新, 以适应不断演进的应用需求和技术挑战。这些特性使得 MySQL 成为在数据密集型环境

中，尤其是 Web 应用领域中，一个不可或缺的技术选择。

MyBatis 是一个半 ORM 框架，它通过 SQL 映射的方式，允许开发者编写原生 SQL 语句，从而提供灵活的数据库操作。MyBatis 支持动态 SQL，能够根据条件构建不同的 SQL 语句，这对于处理复杂的业务逻辑非常有用。此外，MyBatis 易于集成，可以与 Spring 等框架无缝配合，支持事务管理。MyBatis 的灵活性和性能优化使其成为许多 Java 项目中的首选数据访问层框架。

5.2.2 地铁客流量分析平台系统架构设计

在考虑系统模块的具体需求后，设计了一个分层的系统架构。本系统的架构被划分为数据采集层、数据存储层、数据处理层、数据统计分析层以及数据可视化层。架构如图 5-1 所示。




图 5-1 系统架构图

Figure 5-1 System architectures

(1) 数据采集层

数据采集层是系统架构的基础，负责从各种数据源读取数据并进行汇总。在这个层次中，最关键的是乘客流量刷卡事务的原始数据记录。这些记录是后续深度分析和研究的基础。数据采集层的设计考虑了数据源的多样性和复杂性，包括地铁刷卡数据、用户行为数据、网络日志等。

(2) 数据存储层

数据存储层负责数据的存储和预处理工作。由于本文所涉及的数据量极为庞

大，该层级初始步骤包括对收集到的数据执行分库与分表的操作。数据主要储存在数据服务器的 MySQL 和 Redis TimeSeries 中，其中 MySQL 负责存储经过预处理后的数据记录，而 Redis TimeSeries 则为之后的窗口聚合计算提供必要的技术支持。

（3）数据分析层

在经过恰当的整理和存储之后，数据将成为支持多元化应用场景的坚实基石。数据分析的过程主要分为两个关键阶段：数据预处理和统计分析。数据处理环节作为系统的核心，承担着对存储数据进行深入处理和转换的重任，确保统计分析和数据可视化能够顺畅进行。在这一至关重要的环节中，采用了包括数据清洗、数据转换在内的多项技术，目的是为了从复杂的数据中提取出关键特征和信息。在统计分析层面，利用 Redis TimeSeries 进行数据聚合统计，依据不同的站点和时间段进行精确的计算，并将这些宝贵的统计成果持久化到 MySQL 数据库中。这一精细化的处理流程，不仅为站点排名和模型训练提供了至关重要的数据支撑，同时也提升了对细节数据的检索和查询功能，为数据驱动的决策制定奠定了坚实的基础。

（4）数据可视化层

数据可视化层呈现了一系列图表，这些图表展现了具有较高流量的站点的排名，以及站点客流量随时间动态变化的趋势。这些视觉辅助工具不仅提升了数据的可解读性，也加深了对数据模式的洞察力。数据可视化层的目标是将复杂的数据信息转化为直观和易理解的视觉表达，以支持用户的决策和行动。




图 5-2 系统功能设计

Figure 5-2 System function design

通过上小节的需求分析，对平台的具体功能进行了设计。平台主要包括用户管理模块、权限管理模块、热点站点统计模块、流量窗口统计模块以及流量预测展示模块，如图 5-2 所示。

5.3 地铁客流量分析平台实现

在前文所述功能设计框架的基础上，本节进一步探究了各模块的具体实现及其效果。本文通过展示各模块的功能实现，旨在实证检验所提出系统设计的可行性与实用性。本文以 2019 年 1 月 1 日至 1 月 25 日期间，杭州市区地铁系统产生的刷卡数据集为研究对象，该开放数据集全面记录了 25 天的地铁运营情况，覆盖了 3 条主要地铁线路及其 80 个沿线站点。数据集包含约 7000 万条刷卡记录，为城市交通流量的定量分析提供了丰富的原始数据资源。

(1) 用户管理

用户管理模块是一个多功能的系统组件，它提供了一系列关键功能以维护用户信息的完整性和可访问性。该模块的核心功能包括用户记录的创建、用户信息的检索、用户数据的删除，以及数据的导出机制。这些功能不仅确保了用户数据的有效管理，而且为系统管理员提供了灵活的数据操作手段。



图 5-3 用户管理

Figure 5-3 User management module

(2) 权限管理

权限管理模块，作为系统安全架构的关键组成部分，其设计核心在于实现精细化的访问控制。该模块依托于一套细致的权限分配策略，旨在根据用户角色的预定义属性，动态地配置和调节用户访问权限。这种动态权限调整机制，不仅确保了系统资源的合理划分，而且对系统资源实施了有效的保护措施。通过这种差异化的访问控制方法，权限管理模块极大地提升了系统的安全性，同时保持了操作的灵活性。该模块的设计允许系统根据用户的角色和需求，授予相应的访问级别，从而使得系

统能够适应多变的运行环境 and 安全需求。



图 5-4 权限管理

Figure 5-4 Authority management module

(3) 热门站点排行

热门站点排行榜通过对每日各站点的客流量进行统计分析，提供了一个按热度排序的客流量排名。此排行榜能够反映出各站点在特定时间段内的人气和访问量，为站点流量的动态监控和评估提供了科学依据。通过这种方式，可以有效地揭示出哪些站点在用户中最受欢迎，从而指导相关决策制定和资源配置。




图 5-5 热门站点排行榜

Figure 5-5 Popular station rankings

(4) 站点时间窗口聚合统计

在地铁流量分析中，站点流量的时间聚合统计是至关重要的一环。本文采用了 Redis TimeSeries，利用其专为时间序列数据设计的存储和查询机制，实现了对站点流量的动态统计与分析。通过设定特定的时间间隔，Redis TimeSeries 的聚合查询功能能够依据预设的时间间隔对站点的进出流量进行精确统计，从而提供了一种既精确又系统的数据统计方法。利用 Redis TimeSeries 的高效数据结构和聚合算法，

这一过程不仅显著提升了数据处理流程的效率，同时也确保了数据的精确度和可信度。更为重要的是，这种高效的数据聚合方式，为后续的流量分析与预测提供了坚实的数据基础。因此，Redis TimeSeries 的时间序列聚合功能在站点流量管理和分析中发挥着关键作用，其优化的数据存储和实时处理能力为站点流量的深入研究提供了强有力的技术支撑。




图 5-6 站点流量聚合统计

Figure 5-6 Station flow aggregate statistics

(5) 明细数据查询

数据检索模块的构建旨在提供一种先进的查询方案，依据用户设定的唯一标识符以及其指定的时间段，对庞大的数据集中进行精准细致的搜索操作。通过精心设置本模块的各项功能参数，确保能够有针对性地从海量数据中筛选出与既定用户参数及时间约束条件完全吻合的原生数据子集。界面见图 5-7。




图 5-7 站点明细数据

Figure 5-7 Station detail data

明细数据查询，不仅显著提升了数据检索的工作效率，同时还极大优化了数据的易用性，使得用户可以根据自身特定的查询需求，迅速且精确地定位到所需要的

数据信息。

(6) 流量预测

站点数据预测功能是一种先进的分析工具，它使用户能够通过执行精确的查询操作来检索数据库中存储的模型生成的预测结果。这一功能的核心是一个预测算法，该算法通过对大量历史数据进行综合分析，以识别和预测未来的发展趋势。通过这种方式，它能够展示一系列可能的结果，并为用户提供了一个强有力的决策支持系统。这不仅增强了决策的科学性和准确性，而且还提高了操作的效率和效果，使得用户能够在复杂的数据环境中做出更加明智的选择。




图 5-8 站点流量预测数据

Figure 5-8 Station flow forecast data

(7) 系统监控

系统监控工具是确保信息系统稳定运行的关键，它们负责全面监控系统的运行状态。具体监测内容包括应用程序接口（API）调用频率、数据库访问模式、系统负载、响应时间等关键性能指标。这些工具为系统管理员提供了详尽的数据资源，使得他们能够对系统性能进行精确评估，并优化资源配置以提升效率。监控工具通过实时数据分析，能够迅速识别并预警潜在的系统问题，从而采取预防措施，确保系统的稳定运行。

此外，系统监控工具在保障系统安全性和改善用户体验方面发挥着重要作用。它们通过实时监控系统行为，能够有效地识别异常活动，预防安全威胁，并及时响应以减少对用户的影响。例如，通过设置阈值和自动响应策略，监控工具可以在检测到异常流量或未授权访问时自动触发警报或采取隔离措施。这样的机制不仅提

高了系统的防御能力，也增强了用户对系统的信任和满意度。界面见图 5-9。



5-9 系统监控

Figure 5-9 System monitoring

5.4 本章小结

本章深入探讨了地铁客流量可视化平台的系统设计与实际构建，其核心内容围绕着现代软件开发的前沿技术与设计理念。平台的构建基础是 Element UI 框架与 SpringBoot 技术的集成，这种选择体现了对模块化、高效开发模式的深刻理解。系统采用了 MVC 架构，以及前后端分离的开发模式，旨在提升系统的灵活性、可维护性和用户体验。这种架构设计确保了数据处理的高效性和用户界面的流畅性，使得信息的呈现与交互达到了无缝衔接。

平台的核心功能模块涵盖了用户管理、权限控制、热点站点流量统计、流量趋势分析以及预测模块。用户管理模块负责用户身份的认证与权限的分配，确保数据的安全性和准确性。权限控制模块则确保只有授权的用户才能访问和操作特定的数据，保障了系统的稳定运行。热点站点流量统计模块通过对大量数据的实时分析，揭示了地铁客流量的热点区域，为决策者提供了关键的运营信息。流量趋势分析模块则通过数据挖掘技术，揭示了客流量的动态变化规律，为预测未来的客流量提供了科学依据。预测模块则基于历史数据和趋势分析，为地铁系统的运营调度提供了前瞻性的决策支持。从实际需求出发，详尽地剖析了平台的系统架构设计，包括模块划分、数据流管理以及系统集成策略。功能规划阶段，充分考虑业务需求的复杂性和多样性，以确保各个模块的协同工作能够满足复杂的数据分析任务。通过模块间的高效协作，不仅优化了地铁系统的运行效率，还显著提升了乘客的出行体验，

实现了数据驱动的智能运营。

总之，本文章节全面探讨了地铁客流量可视化平台的综合性设计与实施策略。通过现代技术架构的合理构建，本文展示了如何通过精心设计的数据架构和功能模块，实现高效的数据处理能力、用户交互性以及对复杂数据集的深入分析。这一平台的开发，为地铁客流管理与优化提供了一种强有力的辅助工具，不仅优化了地铁系统的运营效率，而且显著提升了乘客的出行体验。

6 总结与展望

6.1 工作总结

在城市地铁交通系统的规划与运营中，精准地预测客流量是一项极为关键的任务。鉴于地铁客流量数据所呈现的复杂时空相关性，预测工作的难度相应增加。为了克服这一挑战，本文采纳了一种在时间和空间两个维度上对客流量数据进行深入分析的方法论。此方法通过分别考虑时间变化和空间分布的影响，显著提升了预测的精确度。主要研究内容如下：

(1) 本文首先提出了一种基于动态学习图的客流量预测模型。该模型运用动态图卷积网络来捕捉铁路网络中的时空关系。与传统的静态图卷积网络相比，该模型采用数据驱动的方式动态构建邻接矩阵，更为有效地揭示了节点间随时间演变的联系。通过参数化的邻接矩阵，模型能够自适应地学习和更新时间图，从而提高预测的准确性。

(2) 进一步地，本文探讨了一种融合周期性特征和元学习的客流量预测模型。该模型通过引入时间嵌入和元学习机制，增强了对周期性变化的捕捉能力，并提高了模型对新数据的适应性。时间嵌入使得模型能够理解和利用时间信息。此外，元学习策略的融入，通过构建记忆节点并运用对比学习技术，进一步强化了模型对新数据集的适应性和泛化能力。这种元学习机制，通过内部数据的模式识别，促进了模型对未见过数据的预测准确性。

(3) 最后，本文介绍了一个地铁客流量分析平台的设计与实现。该平台不仅满足了系统需求，还采用了先进的时间序列数据处理方法，提供了多功能的分析工具。平台的设计充分考虑了用户体验，使得功能实现直观且易于操作。

通过一系列对比实验和消融实验，本文验证了所提出模型的有效性。实验结果表明，动态学习图模型和融合周期特征的元学习模型在客流量预测方面均优于现有方法。这些模型的成功实现，为交通系统的客流量预测提供了新的视角和工具，有望在实际应用中发挥重要作用。总体而言，本文的成果为地铁客流量的数据分析和预测提供了宝贵的参考和指导。

6.2 工作展望

在未来的研究工作中，本文计划深入挖掘多个关键领域，以增强预测模型的效

能和实际应用潜力。以下是未来研究路线图的主要内容：

（1）算法优化与模型迁移

本文将专注于算法优化和数据分析技术的创新。计划探索并实施前沿的机器学习和深度学习算法，特别是无监督学习技术。在多样化的数据集上进行广泛的验证，旨在持续提升模型的预测精度，并确保其在实际应用中的可靠性和有效性。考虑到现有模型日益增长的复杂性对实际应用的效率和可扩展性构成的挑战，开发简洁高效的流量预测方法，实现快速部署和实施，变得尤为关键。此外，将关注模型的适应性和迁移能力，研究如何利用迁移学习和联邦学习等技术，使模型能够迅速适应新环境，减少重新训练的需求和成本，提升模型的实用性和推广价值。

（2）多源数据融合

计划探索多源数据融合潜力^[68]。地铁客流量预测不仅依赖于历史客流数据，还可以从天气状况、节假日安排、重大事件等外部因素中获取数据。这些因素对客流量的影响不容忽视。通过融合多源数据，可以进一步提高预测模型的准确性和鲁棒性。计划整合更多外部数据源，并应用深度学习中的多模态学习技术，有效整合这些数据至预测模型中。

（3）系统功能扩展

本文将扩展系统的功能，超越单一的客流量预测，扩展至交通流的实时监测和拥堵预警。这需要增强数据采集和处理能力，利用大数据技术实现海量流量数据存储，以及采用实时计算技术进行流量数据分析，以满足动态交通环境中对实时性和响应性的高要求，实现对城市交通系统的全面动态管理。

（4）加强合作

加强与实际运营部门的合作，确保研究成果能够转化为实际应用。计划与地铁运营公司建立紧密的合作关系，通过试点项目验证模型的实际效果，并根据反馈不断优化和改进模型。此外，将开发一套全面的评估体系，从多个维度评估模型性能，确保其在实际应用中的可靠性和有效性。

通过这些策略，预期在算法优化、多源数据融合、模型可解释性、架构改进、适应性和迁移能力提升方面取得显著进展。通过与实际运营部门的紧密合作，进一步提升地铁客流量预测模型的性能和实际价值，为地铁客流量预测领域带来创新成果。

参考文献

- [1] 王福文, 冯爱军. 2022 年我国城市轨道交通数据统计与发展分析[J].隧道建设(中英文),2023,43(03):521-528.
- [2] 蔡昌俊, WU Shang. 加速“智慧城轨”建设助力城市轨道交通高质量发展[J].城市轨道交通研究,2023,26(12):3+280.
- [3] “十四五”现代综合交通运输体系发展规划[J]. 铁道技术监督, 2022, 50(2):9-23, 27.
- [4] Jing L, Wei G. A Summary of Traffic Flow Forecasting Methods[J]. Journal of Highway and Transportation Research and Development, 2004.25-60.
- [5] Ahmed M S, Cook A R. Analysis of freeway traffic time-series data by using Box-Jenkins techniques[M]. 1979.60-89.
- [6] 赵晓丽. ARIMA 模型在城市轨道交通短期客流预测中的应用研究[J]. 现代城市轨道交通,2023(8):77-82.
- [7] 张国赞, 金辉. 基于改进 ARIMA 模型的城市轨道交通短时客流预测研究[J]. 计算机应用与软件, 2022, 39(1):339-344.
- [8] 成向立. 基于灰色预测理论的轨道交通站点客流预测[J]. 智能城市,2020,6(1):139-140
- [9] 褚文斌,倪汪凌,马竞驰. 城市轨道交通客流规模偏差影响因素研究[J]. 智能城市,2023,9(8):17-19.
- [10] 周欣荣,沙海云,高文宝,等. 卡尔曼滤波在短时段交通预测上的应用[C]. //第一届中国智能交通年会论文汇编. 2005:11-16.
- [11] 刘静,关伟. 交通流预测方法综述[J]. 公路交通科技,2004,21(3):82-85.
- [12] Davis G A, Nihan N L. Nonparametric regression and short-term freeway traffic forecasting[J]. Journal of transportation engineering, 1991, 117(2): 178-188.
- [13] 彭挺,周涛,蔡晓禹. 基于属性加权回归的组团式城市轨道交通进出站客流预测模型研究[J]. 交通运输系统工程与信息,2023,23(1):176-186,197.
- [14] 谢俏,李斌斌,何建涛,等. 基于非参数回归的城轨实时进出站客流预测[J]. 都市快轨交通,2017,30(2):32-36.
- [15] 郇宁,谢俏,叶红霞,等. 基于改进 KNN 算法的城轨进站客流实时预测[J]. 交通运输系统工程与信息,2018,18(5):121-128.
- [16] Wu C H, Ho J M, Lee D T. Travel-time prediction with support vector regression[J]. IEEE Transactions on Intelligent Transportation Systems, 2004, 5(4):276-281.
- [17] 韩皓,徐圣安,赵蒙.考虑线网结构的 LightGBM 轨道交通短时客流预测模型[J].铁道运输与经济,2021,43(10):109-117.
- [18] Yu Y, Si X, Hu C, et al. A review of recurrent neural networks: LSTM cells and network architectures[J]. Neural computation, 2019, 31(7): 1235-1270.
- [19] Bai S, Kolter J Z, Koltun V. An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling[J]. 2018.
- [20] Sutskever I, Vinyals O, Le Q V. Sequence to sequence learning with neural networks[C]//Proceedings of the 27th International Conference on Neural Information Processing Systems - Volume 2. Cambridge, MA, USA: MIT Press, 2014: 3104-3112.
- [21] Zhang S, Tong H, Xu J, et al. Graph convolutional networks: a comprehensive review[J].

- Computational Social Networks, 2019, 6(1): 1-23.
- [22] Gu J, Wang Z, Kuen J, et al. Recent advances in convolutional neural networks[J]. Pattern recognition, 2018, 77: 354-377.
- [23] Du B, Peng H, Wang S, et al. Deep irregular convolutional residual LSTM for urban traffic passenger flows prediction[J]. IEEE Transactions on Intelligent Transportation Systems, 2019, 21(3): 972-985.
- [24] Wu H, Tang Y, Fei R, et al. Traffic Flow Prediction Model and Performance Analysis Based on Recurrent Neural Network[C]//The 10th International Conference on Computer Engineering and Networks. Springer Singapore, 2021: 429-438.
- [25] Li F, Feng J, Yan H, et al. Dynamic graph convolutional recurrent network for traffic prediction: Benchmark and solution[J]. ACM Transactions on Knowledge Discovery from Data, 2023, 17(1): 1-21.
- [26] Ye T, Zou F, Guo F. Expressway Short-Term Traffic Flow Prediction Based on CNN-LSTM[C]//International Conference on Genetic and Evolutionary Computing. Singapore: Springer Nature Singapore, 2023: 29-36.
- [27] Wang X, Ma Y, Wang Y, et al. Traffic flow prediction via spatial temporal graph neural network[C]//Proceedings of the web conference 2020. 2020: 1082-1092.
- [28] Yu B, Yin H, Zhu Z. Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting[C]//Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence. Stockholm, Sweden: International Joint Conferences on Artificial Intelligence Organization, 2018: 3634-3640.
- [29] Li Y, Yu R, Shahabi C, et al. Diffusion Convolutional Recurrent Neural Network: Data-Driven Traffic Forecasting[C]//International Conference on Learning Representations. 2018.
- [30] Zhang J, Shi X, Xie J, et al. GaAN: Gated Attention Networks for Learning on Large and Spatiotemporal Graphs[C]//Conference on Uncertainty in Artificial Intelligence. 2018:339–349.
- [31] Wu Z, Pan S, Long G, et al. Graph WaveNet for Deep Spatial-Temporal Graph Modeling[C]//International Joint Conference on Artificial Intelligence. 2019:1907–1913.
- [32] Guo S, Lin Y, Feng N, et al. Attention Based Spatial-Temporal Graph Convolutional Networks for Traffic Flow Forecasting[C]//AAAI Conference on Artificial Intelligence. 2019: 922-929.
- [33] Geng X, Li Y, Wang L, et al. Spatiotemporal Multi-Graph Convolution Network for Ride-Hailing Demand Forecasting[C]//AAAI Conference on Artificial Intelligence. 2019: 3656-3663.
- [34] Pan Z, Liang Y, Wang W, et al. Urban Traffic Prediction from Spatio-Temporal Data Using Deep Meta Learning[C]//Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. Anchorage AK USA: ACM, 2019: 1720-1730.
- [35] Huang R, Huang C, Liu Y, et al. LSGCN: Long Short-Term Traffic Prediction with Graph Convolutional Networks[C]//Proceedings of the Twenty-Ninth International Joint Conference on Artificial Intelligence. Yokohama, Japan: International Joint Conferences on Artificial Intelligence Organization, 2020: 2355-2361.
- [36] Song C, Lin Y, Guo S, et al. Spatial-Temporal Synchronous Graph Convolutional Networks:

- A New Framework for Spatial-Temporal Network Data Forecasting[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2020, 34(01): 914-921.
- [37] Zheng C, Fan X, Wang C, et al. GMAN: A Graph Multi-Attention Network for Traffic Prediction[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2020, 34(01): 1234-1241.
- [38] Wu Z, Pan S, Long G, et al. Connecting the Dots: Multivariate Time Series Forecasting with Graph Neural Networks[C]//Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. Virtual Event CA USA: ACM, 2020: 753-763.
- [39] Bai L, Yao L, Li C, et al. Adaptive Graph Convolutional Recurrent Network for Traffic Forecasting[C]//Neural Information Processing Systems, 2020:17804-17815.
- [40] Lu B, Gan X, Jin H, et al. Spatiotemporal Adaptive Gated Graph Convolution Network for Urban Traffic Flow Forecasting[C]//Proceedings of the 29th ACM International Conference on Information & Knowledge Management. Virtual Event Ireland: ACM, 2020: 1025-1034.
- [41] Lv M, Hong Z, Chen L, et al. Temporal Multi-Graph Convolutional Network for Traffic Flow Prediction[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 22: 3337-3348.
- [42] Chen W, Chen L, Xie Y, et al. Multi-Range Attentive Bicomponent Graph Convolutional Network for Traffic Forecasting[C]//Association for the Advancement of Artificial Intelligence, 2020, 3529-3536.
- [43] Wang X, Ma Y, Wang Y, et al. Traffic Flow Prediction via Spatial Temporal Graph Neural Network[C]//Proceedings of The Web Conference 2020. Taipei Taiwan: ACM, 2020: 1082-1092.
- [44] Shang C, Chen J, Bi J. Discrete Graph Structure Learning for Forecasting Multiple Time Series[C]International Conference on Learning Representations,2021:200-211.
- [45] Li F, Feng J, Yan H, et al. Dynamic Graph Convolutional Recurrent Network for Traffic Prediction: Benchmark and Solution[J]. ACM Transactions on Knowledge Discovery from Data, 2021, 17: 1-21.
- [46] Li M, Zhu Z. Spatial-temporal fusion graph neural networks for traffic flow forecasting[C]//Proceedings of the AAAI conference on artificial intelligence. 2021, 35: 4189-4196.
- [47] Ye J, Sun L, Du B, et al. Coupled layer-wise graph convolution for transportation demand prediction[C]//Proceedings of the AAAI conference on artificial intelligence. 2021, 35(5): 4617-4625.
- [48] Fang Z, Long Q, Song G, et al. Spatial-Temporal Graph ODE Networks for Traffic Flow Forecasting[J]. Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining, 2021: 364-373.
- [49] Han L, Du B, Sun L, et al. Dynamic and Multi-faceted Spatio-temporal Deep Learning for Traffic Speed Forecasting[J]. Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining, 2021: 547-555.
- [50] Yu123 H, Li T, Yu23 W, et al. Regularized Graph Structure Learning with Semantic Knowledge for Multi-variates Time-Series Forecasting[J].2023:1-10

- [51] Ye J, Liu Z, Du B, et al. Learning the Evolutionary and Multi-scale Graph Structure for Multivariate Time Series Forecasting[J]. Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, 2022: 2296-2306.
- [52] Shao Z, Zhang Z, Wang F, et al. Pre-training Enhanced Spatial-temporal Graph Neural Network for Multivariate Time Series Forecasting[J]. Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, 2022: 1567–1577.
- [53] Choi J, Choi H, Hwang J, et al. Graph neural controlled differential equations for traffic forecasting[C]//Proceedings of the AAAI conference on artificial intelligence. 2022, 36(6): 6367-6374.
- [54] Lan S, Ma Y, Huang W, et al. Dstagnn: Dynamic spatial-temporal aware graph neural network for traffic flow forecasting[C]//International conference on machine learning. PMLR, 2022: 11906-11917.
- [55] Liu L, Chen J, Wu H, et al. Physical-Virtual Collaboration Modeling for Intra- and Inter-Station Metro Ridership Prediction[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 23: 3377-3391.
- [56] Xiao W, Wang X. Spatial-Temporal Dynamic Graph Convolutional Neural Network for Traffic Prediction[J]. IEEE Access, 2023, 11: 97920-97929.
- [57] Ji J, Yu F, Lei M. Self-Supervised Spatiotemporal Graph Neural Networks With Self-Distillation for Traffic Prediction[J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24: 1580-1593.
- [58] Lou H, Ma Y, Li J. Dynamic graph convolution recurrent neural network for traffic flow prediction[C]//Third International Conference on Artificial Intelligence, Virtual Reality, and Visualization (AIVRV 2023). SPIE, 2023, 12923: 473-482.
- [59] Yuanbo X, Xiao C, En W, Wenbin L, Yongjian Y, Funing Y, et al. Dynamic traffic correlations based spatio-temporal graph convolutional network for urban traffic prediction[J]. Information Sciences, 2023, 621: 580-595.
- [60] Zhengyan C, Junjun Z, Giseop N, Hyun J P, et al. ADSTGCN: A Dynamic Adaptive Deeper Spatio-Temporal Graph Convolutional Network for Multi-Step Traffic Forecasting.[J], Sensors, 2023, 23(15): 6950-6950.
- [61] Chen Y, Shu T, Zhou X, et al. Graph attention network with spatial-temporal clustering for traffic flow forecasting in intelligent transportation system[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 24(8): 8727-8737.
- [62] Jin G, Liang Y, Fang Y, et al. Spatio-temporal graph neural networks for predictive learning in urban computing: A survey[J]. IEEE Transactions on Knowledge and Data Engineering, 2023:1-20.
- [63] Pan Z, Liang Y, Wang W, et al. Urban Traffic Prediction from Spatio-Temporal Data Using Deep Meta Learning[J]. Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, 2019: 1720–1730.
- [64] Li R, Zhong T, Jiang X, et al. Mining Spatio-Temporal Relations via Self-Paced Graph Contrastive Learning[J]. Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, 2022:936–944.
- [65] Jiang R, Wang Z, Yong J, et al. Spatio-temporal meta-graph learning for traffic

- forecasting[C]//Proceedings of the AAAI Conference on Artificial Intelligence: 2023: 8078-8086.
- [66] Shin Y , Yoon Y. PGCN: Progressive Graph Convolutional Networks for Spatial–Temporal Traffic Forecasting[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 25: 7633-7644.
- [67] Shao Z, Zhang Z, Wang F, et al. Spatial-Temporal Identity: A Simple yet Effective Baseline for Multivariate Time Series Forecasting[C]//Proceedings of the 31st ACM International Conference on Information & Knowledge Management. Atlanta GA USA: ACM, 2022: 4454-4458.
- [68] 户佐安,邓锦程,韩金丽,等.图神经网络在交通预测中的应用综述[J].交通运输工程学报,2023,23(05):39-61.

学位论文数据集

表 1.1： 数据集页

关键词*	密级*	中图分类号	UDC	论文资助
地铁客流量预测；图神经网络；动态时空图；周期特征；元学习	公开			
学位授予单位名称*		学位授予单位代码*	学位类别*	学位级别*
北京交通大学		10004	电子信息	硕士
论文题名*		并列题名*		论文语种*
基于时空图神经网络的地铁客流量预测模型研究		基于时空图神经网络的地铁客流量预测模型研究		中文
作者姓名*	潘路远		学号*	20140064
培养单位名称*		培养单位代码*	培养单位地址	邮编
北京交通大学		10004	北京市海淀区西直门外上园村 3 号	100044
专业学位类别（领域）*		研究方向*	学制*	学位授予年*
软件工程		数据挖掘	2	2024
论文提交日期*	2024 年 9 月			
导师姓名*	黄华		职称*	副教授
评阅人	答辩委员会主席*		答辩委员会成员	
	胡绍海		刘海洋 陆杨	
电子版论文提交格式 文本（ ✓ ） 图像（ ） 视频（ ） 音频（ ） 多媒体（ ） 其他（ ） 推荐格式：application/msword； application/pdf				
电子版论文出版（发布）者		电子版论文出版（发布）地		权限声明
论文总页数*	65			
共 33 项，其中带*为必填数据，为 21 项。				